

Claude Certified Architect — Foundations Certification

مطالعہ گائیڈ (سرکاری امتحانی گائیڈ کی بنیاد پر)

تعارف

سرٹیفیکیشن اس بات کی تصدیق کرتی ہے کہ ایک ماہر حقیقی Claude Certified Architect — Foundations Claude Code، Claude Agent SDK، Claude API، اور Model Context Protocol (MCP) — یعنی بنیادی علم کا جائزہ لیتا ہے — کے ساتھ پروڈکشن ایپلیکیشنز بنائی جاتی ہیں۔ Claude و بنیادی ٹیکنالوجیز جن سے

agentic systems امتحانی سوالات حقیقت پسندانہ صنعتی منظرناموں پر مبنی ہوتے ہیں: کسٹمر سپورٹ کے لیے، multi-agent research pipelines، ڈیزائن کرنا، Claude Code کو CI/CD میں ضم کرنا، developer productivity، structured data بنانا، اور غیر ساختہ دستاویزات سے tools نکالنا۔

هدف امیدوار

کرتا ہے آپ ship کے ساتھ پروڈکشن ایپلیکیشنز ڈیزائن اور Claude کے جو solution architect مثالی امیدوار ایک کے پاس کم از کم 6 ماہ کا عملی تجربہ ہونا چاہیے:

- Claude Agent SDK** — multi-agent orchestration، subagents کو delegate کرنا، tool integration، lifecycle hooks
- Claude Code** — CLAUDE.md، MCP servers، Agent Skills، planning mode
- Model Context Protocol (MCP)** — backend integration کے لیے tools اور resources
- Prompt engineering** — JSON schemas، few-shot examples، data extraction templates
- Context windows** — لمبی دستاویزات کے ساتھ کام، multi-agent context passing
- CI/CD pipelines** — automated code review، test generation
- Escalation and reliability** — error handling، human-in-the-loop

امتحانی فارمیٹ

پیرامیٹر	قدر
سوال کی قسم	Multiple choice (میں سے 1 درست 4)
اسکورنگ	100–1000 scale، passing score 720
Guessing penalty	نہیں (سوال کا جواب دیں!)
Scenarios	8 4 (randomly selected) میں سے

امتحانى مواد: 5 ڈومينز

وزن	ڈومین
27%	1. Agent architecture and orchestration
18%	2. Tool design and MCP integration
20%	3. Claude Code configuration and workflows
20%	4. Prompt engineering and structured output
15%	5. Context management and reliability

امتحان منظر نام

Scenario 1: Customer Support Agent

account اور، returns، billing disputes استعمال کرتے ہوئے Claude Agent SDK بناتے ہیں جو آپ ایک agent MCP tools (`get_customer`، `lookup_order`، `process_refund`، `escalate_to_human`) سنبھالتا ہے، مناسب first-contact resolution + % استعمال کرتا ہے 80 دفعہ (`escalation`، `escalate_to_human`) ساتھ۔

Scenario 2: Claude Code Code Generation

code generation, refactoring, debugging, documentation اور custom slash commands کے ساتھ، آپ کو اسے development میں استعمال کرتے ہوئے Claude Code کے ساتھ integrate کرنا اور planning mode کرنا، اور سمجھنا کے integrate

Scenario 3: Multi-Agent Research System

تیار کرنا، جاننا، reports کو مکمل citations سسٹم کو report generation اور synthesis tasks کو specialized subagents اور coordinator agent سونپنا

Scenario 4: Developer Productivity Tools

□ agent engineers کو unfamiliar codebases explore کرنے، boilerplate code اور routine tasks automate □□□ میں مدد دیتا □□ Built-in tools (Read, Write, Bash, Grep, Glob) اور MCP servers استعمال □□□ کد □□□ جاز□□□ ہیں □□

Scenario 5: Claude Code for Continuous Integration

Claude Code اور pull request automated code reviews، test generation میں ضم کریں تاکہ CI/CD pipeline کو Claude Code request feedback کم سے کم false positives ڈیزائن ہونے چاہئیں کہ Prompts حاصل ہو۔

Scenario 6: Structured Data Extraction

کرتا ہے، validate کے ذریعے JSON schemas کو output، سسٹم غیر ساختہ دستاویزات سے معلومات نکالتا ہے اور کو درست طور پر سنبھالنا چاہیے۔ edge cases پر برقرار رکھتا ہے اسے high accuracy اور

Scenario 7: Conversational AI Architecture Patterns

turns متعدد، context window management ڈیزائن کرتا ہے۔ جن میں multi-turn conversational systems آپ اور مہم یا متضاد، tool design کے لیے execution محفوظ، memory strategies، کا برقرار رکھنا instructions میں user inputs کو سنبھالنا شامل ہے۔

Scenario 8: Agentic AI Tools (ہماری مدد کریں — مواد موجود نہیں)

میں شامل نہیں۔ guide نہ دی لیکن ابھی تک اس candidates کی اطلاع امتحان دینا والے scenario اس کریں share میں GitHub Issues کے سوالات دیکھیں، تو انہیں scenario کے اصل امتحان میں اس شامل کر سکیں۔ آپ کا تعاون۔ اس شخص کی مدد کرے گا جو امتحان کی تیاری کر coverage تاکہ ہم مکمل رہے۔

سرکاری دستاویزات

وسیلہ	URL
Claude API — Messages	https://platform.claude.com/docs/en/api/messages
Claude API — Tool Use	https://platform.claude.com/docs/en/build-with-claude/tool-use
Claude API — Message Batches	https://platform.claude.com/docs/en/build-with-claude/message-batches
Claude Agent SDK — Overview	https://platform.claude.com/docs/en/agent-sdk/overview
Claude Agent SDK — Hooks	https://platform.claude.com/docs/en/agent-sdk/hooks
Claude Agent SDK — Subagents	https://platform.claude.com/docs/en/agent-sdk/subagents
Claude Agent SDK — Sessions	https://platform.claude.com/docs/en/agent-sdk/sessions
Model Context Protocol (MCP)	https://modelcontextprotocol.io/
MCP — Tools	https://modelcontextprotocol.io/docs/concepts/tools
MCP — Resources	https://modelcontextprotocol.io/docs/concepts/resources
MCP — Servers	https://modelcontextprotocol.io/docs/concepts/servers
Claude Code — Documentation	https://code.claude.com/docs/en/overview
Claude Code — CLAUDE.md and Memory	https://code.claude.com/docs/en/memory
Claude Code — Skills (incl. slash commands)	https://code.claude.com/docs/en/skills

Claude Code — Hooks	https://code.claude.com/docs/en/hooks
Claude Code — Sub-agents	https://code.claude.com/docs/en/sub-agents
Claude Code — MCP Integration	https://code.claude.com/docs/en/mcp
Claude Code — GitHub Actions CI/CD	https://code.claude.com/docs/en/github-actions
Claude Code — GitLab CI/CD	https://code.claude.com/docs/en/gitlab-ci-cd
Claude Code — Headless (non-interactive mode)	https://code.claude.com/docs/en/headless
Prompt Engineering Guide	https://platform.claude.com/docs/en/build-with-claude/prompt-engineering/overview
Extended Thinking	https://platform.claude.com/docs/en/build-with-claude/extended-thinking
Anthropic Cookbook (code examples)	https://github.com/anthropics/anthropic-cookbook

نظریاتی بنیادیں: حصہ ۱

یہ حصہ تمام نظریاتی احاطہ کرتا ہے جس کی آپ کو امتحان میں کامیابی کے لیے ضرورت ہے۔ مواد کو کے مطابق — اس سے آپ کے domains کے مطابق ترتیب دیا گیا ہے، نہ کہ امتحانی concepts ٹیکنالوجیز اور موضوع کی زیادہ گہری سمجھ پیدا کر سکتے ہیں۔

کی بنیادیں Claude API — Model Interaction: باب 1

دستاویزات: [Messages API](#) | [Prompt Engineering](#)

1.1 API Request Structure

Claude API کی request کی ر Claude Messages API کی پیروی کرتا ہے request-response model ایک شامل ہوتا ہے:

```
{
  "model": "claude-sonnet-4-6",
  "max_tokens": 1024,
  "system": "You are a helpful assistant.",
  "messages": [
    {"role": "user", "content": "Hi!"},
    {"role": "assistant", "content": "Hello!"},
    {"role": "user", "content": "How are you?"},
  ],
  "tools": [...],
  "tool_choice": {"type": "auto"}
}
```

□□ م فیلڈر:

- `model` — model selection (`claude-opus-4-6` , `claude-sonnet-4-6` , `claude-haiku-4-5`)
- `max_tokens` — response □□ زیاد □□ زیاد کی تعداد tokens میں زیاد □□ زیاد
- `system` — system prompt (model □□ کی تعریف کرتا □□)
- `messages` — conversation history (history تسلسل برقرار رکھنے □□ لیے □□ آپ کو مکمل) □□)
- `tools` — tools کی definitions دستیاب
- `tool_choice` — tool selection strategy

1.2 Message Roles

`messages` array استعمال کرتا □□ instructional role اور ایک conversational roles دو:

- `user` — user messages, `tool_result` □□ اندر `user`-role message (ایک □□ `tool_result` content block □□ کی صورت میں بھیجا جاتا □□، ایک الگ `tool` role □□ میں بھیجتے وقت شامل کیے جاتے □□ history) `tool_use` content blocks)
- `assistant` — model responses (history □□ میں بھیجتے وقت شامل کیے جاتے □□، `tool_use` content blocks)
- `system` — top-level `system` field □□ سیٹ کیا جا سکتا □□ (□□ turn □□) □□ ذریعے □□ سیٹ کیا جا سکتا □□ اس نقطہ □□ آگے) شامل کیا جا سکتا □□ inline □□ طور پر `messages` میں `{"role": "system", ...}` □□، مخصوص (□□ تابع — نیچے دیکھیں placement rules لاگو □□ ہوتا □□،

□□ طور `user`-role message □□ طور پر □□ میں بھیجا جاتا □□ ایک message □□ role `"tool"` کو Tool results □□ شامل □□ ہوتا □□ `tool_result` content block □□ میں ایک content پر بھیجا جاتا □□ میں جس □□

```
{
  "role": "user",
  "content": [
    {
      "type": "tool_result",
      "tool_use_id": "toolu_01...",
      "content": "...
    }
  ]
}
```

top-level کے طور پر ظاہر ہو سکتا ہے، نہ صرف role میں بھی ایک array messages براہ راست system کے بغیر invalidate prefix کو cached field کے top-level کے ذریعے اس کا مقصد system parameter placement rules شامل کرنا ہے اس کے مخصوص instructions کے درمیان conversation:

- پر ختم ہونے والے server tool use یا (ہوں blocks tool_result بشمول وہ جس میں) user turn یا ایک assistant turn کے فوراً بعد آنا چاہیے۔
- ہونا چاہیے element کا آخری array سد پہلے آنا چاہیے یا assistant turn کسی کسی
- ملتا error کے درمیان نہیں آ سکتا — ایسا کرنے پر 400 tool_result اور اس کے block tool_use کسی کسی
- پہلے والوں پر اور بعد (کے درمیان شامل کیے گئے conversation بشمول) system messages بعد میں آنے والے پر فوقیت رکھتے ہیں۔ field system کے top-level کے لیے turns کے

Model requests بھیجی جا رہی ہیں conversation history میں آپ کو مکمل API request انٹیلیجنس: م۔ ہر آزاد ہوتا ہے call محفوظ نہیں رکھتا — ہر state درمیان

1.3 Response میں stop_reason Field

کیوں روکی generation کے model شامل ہوتا ہے، جو بتاتا ہے کہ stop_reason میں Claude API response

Value	Description	Action
"end_turn"	مکمل کر لیا response کے Model	کو دکھائیں user نتیجہ
"tool_use"	کرنا چاہتا ہے Model tool call	Tool execute اور کریں result دیں
"max_tokens"	Token limit ختم ہو گئی	Response truncated ہے ممکن ہے limit ہے
"stop_sequence"	Stop sequence مل گئی	کریں handle کے مطابق application logic اپنی

Agentic systems میں "end_turn" اور "tool_use" — یہی agent loop سب سے اہم ہیں —

1.4 System Prompt

متعین کرنا ہے behavioral rules اور context کے جو instruction ایک خاص System prompt

- میں دیا جاتا ہے field system کا حصہ نہیں ہوتا؛ الگ array messages

- user messages پر فوقیت رکھتا ہے
- میں لاگو رہتا ہے conversation ہوتا ہے اور پوری load ایک بار
- role, constraints, اور output format استعمال ہوتا ہے

پیدا کر سکتی ہے مثال کے طور پر tool associations کی wording کو system prompt میں لے کر امتحان کر لیں۔ ہم کو ضرورت سے زیادہ `get_customer` کو model کی تصدیق کریں ”جیسی کہ ادیت customer پر،“ ہم ہمیشہ استعمال کرنے پر مجبور کر سکتی ہیں، حتیٰ کہ جب یہ ضروری نہ ہو۔

1.5 Context Window

Context window text (tokens) □□ جس model کی کل مقدار □□ اس میں process ایک وقت میں model کے □□ کر سکتا □□

□□ شامل:

- System prompt
- مکمل message history
- Tool definitions
- Tool results

مسائل context-window

1. **Last-in-the-middle effect:** models input لمبے اعتماد سہ کو زیادہ سے زیادہ معلومات پر موجود معلومات کو زیادہ سے زیادہ استعمال کرتے ہیں۔ اگرچہ یہ ایک بہتر رویہ ہے، مگر درمیان کی تفصیلات process کر سکتے ہیں۔ حل: اہم معلومات شروع یا آخر کے قریب miss کرتے ہیں، مگر درمیان کی تفصیلات رکھیں
2. **Tool results** واپس کر کے tool 40+ fields شامل کرتا ہے۔ اگر output میں tool call context کا جمع ہونا: ہر tool کا بڑا حصہ ضائع ہو جاتا ہے۔ context میں صرف 5 اہم باتوں، تو
3. **Progressive summarization:** history compress کرتے وقت numeric values, percentages, dates اور گیم وغیرہ واضح ہو جاتے ہیں ("تقریباً"، "کچھ"، "چند")

tool_use اور Tools: باب 2

Tool Use: دستاویزات

2.1 tool_use ☐ کیا

برای Model کرنے کی اجازت دیتا ہے کہ external functions کو Claude جو mechanism ایک tool_use result کرتا ہے اور execute اس code بناتا ہے؛ آپ کا structured tool call request میں چلانا — وہ code راست واپس کرتا ہے

2.2 Tool Definition

کے: کیا جاتا ہے define کے ذریعے JSON schema کی tool

```
{
  "name": "get_customer",
  "description": "Finds a customer by email or ID. Returns the customer profile, including name, email, order history, and account status. Use this tool BEFORE lookup_order to verify the customer's identity. Accepts an email (format: user@domain.com) or a numeric customer_id.",
  "input_schema": {
    "type": "object",
    "properties": {
      "email": {"type": "string", "description": "Customer email"},
      "customer_id": {"type": "integer", "description": "Numeric customer ID"}
    },
    "required": []
  }
}
```

کے: انتہائی اہم پہلو Tool description

- Description tool selection mechanism** LLM tools کی بنیاد پر descriptions کو ان کی Minimal descriptions ("Customer information retrieve کرتا کرتا" اُن مواقع پر غلطیوں کا "کرتا کرتا" overlap ایک دوسرے سے tools باعث بنتی ہیں جب کرتے ہیں
- Description میں شامل کریں:**
 - Tool اور کیا واپس کرتا کرتا
 - Input formats اور example values
 - Edge cases اور constraints
 - مقابلہ میں کب استعمال ہو tool similar alternatives
- analyze_content اور analyze_document** سہجے ہیں اگر overlapping descriptions ایک جیسے یا انہیں خلط ملط کر دے گا model تقریباً ایک جیسے ہوں، تو descriptions
- Built-in tools MCP tools:** agents similar functionality والے built-in tools (Read, Grep) MCP tools — مضبوط بنائیں MCP tool descriptions پر ترجیح دے سکتے ہیں اس سے بچدے کے لیے concrete advantages, unique data, context یا و فرام نہیں کر سکتے ہیں

2.3 tool_choice Parameter

کیسے منتخب کرتا کرتا model tools کنٹرول کرتا کرتا tool_choice

Value	Behavior	کب استعمال کریں
{ "type": "auto" }	Model کرنا tool call خود طے کرتا کرتا یا میں جواب دینا text یا	default زیادہ تر حالات میں
{ "type": "any" }	کرنا ہوگی tool call کو لازماً کوئی Model	guaranteed جب آپ کو structured output چاہیں
{ "type": "tool", "name": "extract_metadata" }	کرنی tool call کو لازماً ایک مخصوص ہوگی	forced first step / execution order جب آپ کو چاہیں

2. **Nullable fields:** ایسی معلومات کے لیے `"type": ["string", "null"]` طور پر استعمال کریں جو ممکنہ طور پر `null` ہو سکتا ہے۔
3. **Enums with "other":** predefined categories کے لیے `"other"` شامل کریں + ایک detail string
4. **Enum "unclear":** جب `"unclear"` category غلط ہو تو — ایماندار model category اُن صورتوں کے لیے جب `"unclear"` category غلط ہو

2.5 Syntax Semantic Errors بمقابلہ

Error type	Example	Mitigation
Syntax	Invalid JSON, field type غلط	JSON schema کے ساتھ <code>tool_use</code> (ختم کر دیتا)
Semantic	Totals match نہیں کرتے، value field غلط، hallucination	Validation checks, feedback کے ساتھ retry, self-correction

بنانا Claude Agent SDK — Agentic Systems: باب 3

دستاویزات: [Agent SDK](#) | [Hooks](#) | [Subagents](#) | [Sessions](#)

3.1 Agentic Loop کیا ہے

Agentic loop کی ایک actions صرف جواب نہیں دیتا — وہ Model کے pattern کا بنیادی task execution خودکار sequence انجام دیتا ہے:

- Claude کو tools کے ساتھ request بھیجیں
- Response وصول کریں
- stop_reason چیک کریں:
 - "tool_use" -> tool execute کریں، result history میں append کریں، step 1 پر واپس جائیں
 - "end_turn" -> task مکمل، result user کو دکھائیں
- کریں repeat مکمل ہونے تک

model-driven approach: Claude اپنے context اور tool results پر اگلا tool منتخب کی بنیاد پر۔
تو fixed ہوتا ہے۔ action sequence کے مختلف جہاں hard-coded decision trees کرتا ہے۔

Anti-patterns (ان سے بچیں):

- Completion detect کرنا ("Task completed") assistant text parse کرنے کے لیے
- Primary stop condition طور پر arbitrary iteration limit (مثلاً `max_iterations=5`)
- سمجھنا completion signal دیا یا نہیں، اس کے textual content assistant کے چیک کرنا

درست طریقہ: completion signal کا واحد قابل اعتماد `stop_reason == "end_turn"`

3.2 AgentDefinition Configuration

AgentDefinition Claude Agent SDK میں agent configuration object ہے:


```
agent = AgentDefinition(
    name="customer_support",
    description="Handles customer requests for returns and order issues",
    system_prompt="You are a customer support agent...",
    allowed_tools=["get_customer", "lookup_order", "process_refund",
"escalate_to_human"],
    # Coordinator کے لیے:
    # allowed_tools=["Task", "get_customer", ...]
)
```

parameters:

- name / description — agent کی شناخت اور وضاحت
- system_prompt — system prompt کی ہدایات والا
- allowed_tools — (least privilege اصول) کی فہرست tools اجازت یافتہ

3.3 Hub-and-Spoke: Coordinator اور Subagents

Multi-agent architecture میں بنائی جاتی ہے hub-and-spoke topology عموماً



Coordinator کی ذمہ داریاں:

- Task کو subtasks میں تقسیم کرنا
- (dynamic selection) درکار Subagents میں سے طے کرنا کہ کون سا
- کو سونپنا subagents کام
- کرنا validate نتائج جمع اور
- Errors اور retries handle کرنا
- تک پہنچانا user نتائج

الگ الگ context subagents کا: اصول

- Subagents conversation history کو coordinator سے inherit نہیں کرتے
- میں واضح طور پر دینا ہوتا ہے context subagent prompt تمام ضروری
- Subagents memory share کے درمیان نہیں کرتے
- (observability اور error control کے ذریعے گزرتی ہے communication coordinator تمام کے لیے)

3.4 Subagents **Task Tool** بنانے کے لیے

Subagents **Task** tool کے ذریعے spawn کیے جاتے ہیں:

```
# Coordinator کے allowedTools میں "Task" شامل ہونا چاہیے
coordinator_agent = AgentDefinition(
    allowed_tools=["Task", "get_customer"]
)
```

Explicit context passing لازمی ہے:

```
# Bad: subagent کے پاس context نہیں ہے
Task: "Analyze the document"

# Good: مکمل context prompt میں
Task: "Analyze the following document.
Document: [full document text]
Prior search results: [web search results]
Output format requirements: [schema]"
```

Parallel spawning: subagents parallel — کر سکتا ہے Task s call میں متعدد response ایک coordinator کے چلنے کے لیے:

```
# Coordinator کے ایک response میں شامل ہونے والے Task:
Task 1: "Search for articles about X"
Task 2: "Analyze document Y"
Task 3: "Search for articles about Z"
# تینوں ایک ساتھ چلتے ہیں
```

3.5 Agent SDK میں Hooks

Hooks agent lifecycle کی اجازت دیتے ہیں transformation اور interception پر points کے مخصوص

PostToolUse tool result کو model پر لے کر intercept تک پہنچانے کے لیے:

```
# MCP tools کے تاریخ کو formats normalize کریں: مثال:
@hook("PostToolUse")
def normalize_dates(tool_result):
    # Unix timestamp -> ISO 8601
    # "Mar 5, 2025" -> "2025-03-05"
    return normalized_result
```

Outgoing-call interception hook policy کو block کرنے کے لیے:

```
# کریں refunds block مثال: 500$ سے اوپر
@hook("PreToolUse")
def enforce_refund_limit(tool_call):
    if tool_call.name == "process_refund" and tool_call.args.amount > 500:
        return redirect_to_escalation(tool_call)
```

Hooks اور prompt instructions میں فرق

Attribute	Hooks	Prompt instructions
Guarantee	Deterministic (100%)	Probabilistic (>90%, 100% نہیں)
کب استعمال کریں	Critical business rules, financial operations, compliance	General preferences, recommendations, formatting
مثال	Refunds > \$500 block کریں	"Try to solve before escalating"

استعمال کریں hooks، نہیں prompts — مالی، قانونی، یا حفاظتی نتائج کو failure قاعدہ: جب

باب 4: Model Context Protocol (MCP)

[Servers](#) | [Resources](#) | [Tools](#) | [MCP](#): دستاویزات

4.1 MCP کیا ہے

MCP سے جوڑنا Claude کو external systems جو open protocol ایک (MCP) Model Context Protocol

کرتا ہے resource types define تین بنیادی:

- Tools** — functions (CRUD operations, API calls, command execution) agent actions جنہیں لیں
- Resources** — context agent جسے data کے لیے (documentation, database schemas, content catalogs) پڑھ سکتا ہے
- Prompts** — predefined prompt templates کے لیے tasks عام

4.2 MCP Servers

فرام کرتا ہے جب tools/resources کرتا ہے اور MCP protocol implement کے جو process ایک MCP server

کرتا ہے: MCP server سے connect

- جو جائے ہیں discover خود بخود تمام tools
- ایک ساتھ دستیاب ہوتے ہیں tools کے connected servers تمام
- انہیں کیسے استعمال کرے گا model طے کرتی ہیں کے Tool descriptions

4.3 MCP Servers کو Configure کرنا

Project configuration (`.mcp.json`) — team usage کے لیے:

```
{
  "mcpServers": {
    "github": {
      "command": "npx",
      "args": ["-y", "@modelcontextprotocol/server-github"],
      "env": {
        "GITHUB_TOKEN": "${GITHUB_TOKEN}"
      }
    },
    "jira": {
      "command": "npx",
      "args": ["-y", "mcp-server-jira"],
      "env": {
        "JIRA_TOKEN": "${JIRA_TOKEN}"
      }
    }
  }
}
```

اہم نکات:

- میں `.mcp.json` project root میں محفوظ ہوتا ہے اور version control میں ہوتا ہے
- Environment variables (`${GITHUB_TOKEN}`) secrets کے لیے استعمال ہوتے ہیں
- commit خود tokens — کے لیے استعمال ہوتے ہیں
- contributors کے لیے دستیاب ہوتا ہے

User configuration (`~/.claude.json`) — personal/experimental servers کے لیے:

- User کے home directory میں محفوظ ہوتا ہے
- Version control کے ذریعے share ہوتا ہے
- Personal experiments اور testing کے لیے

Servers کا انتخاب:

- Standard integrations (Jira, GitHub, Slack) موجود ہیں
- community MCP servers کے لیے پبلک سرور موجود ہیں
- کو ترجیح community MCP servers کے لیے پبلک سرور موجود ہیں
- کے لیے بنائیں unique, team-specific workflows صرف custom servers اپنی

4.4 MCP میں isError Flag

کو بتاتا ہے کہ agent استعمال ہوتا ہے یا نہیں `isError: true` میں response آتا ہے تو error میں MCP tool جب call fail ہوئی ہے

Structured error (اچھا):

```
{
  "isError": true,
  "content": {
    "errorCategory": "transient",
    "isRetryable": true,
    "message": "The service is temporarily unavailable. Timeout while calling the orders API.",
    "attempted_query": "order_id=12345",
    "partial_results": null
  }
}
```

Generic error (anti-pattern):

```
{
  "isError": true,
  "content": "Operation failed"
}
```

escalate بدلیں، یا query، کریں retry کو فیصلہ سازی کے لیے کوئی معلومات نہیں دیتا — کیا generic error agent کریں؟

4.5 MCP Resources

کیا: بغیر طلب کر سکتا actions حاصل کرنے کے لیے agent context میں جو ایسا Resources

- Content catalogs (hierarchical navigation، کی فہرست project tasks مثلاً تمام)
- Database schemas (data structure کے لیے سمجھنے کے لیے)
- Documentation (API references، internal guides)
- Issue/task summaries

Resource کا فائدہ: agent کے لیے exploratory tool calls کی ضرورت نہیں پڑتی کے لیے سمجھنے کے لیے agent کے لیے کا فائدہ Resource کا فائدہ: agent کے لیے exploratory tool calls کی ضرورت نہیں پڑتی کے لیے سمجھنے کے لیے

5 اور Claude Code — Configuration Workflows

دستاویزات: [Claude Code](#) | [Memory / CLAUDE.md](#) | [Skills](#) | [MCP](#) | [Hooks](#) | [Sub-agents](#) | [GitHub Actions](#) | [Headless](#)

5.1 CLAUDE.md Hierarchy

hierarchy استعمال کرتا ہے اس کی تین سطحی Claude Code میں جو instruction file(s) و CLAUDE.md ہے:

1. User-level: ~/.claude/CLAUDE.md
 - ہر لاگو user صرف اسی
 - نسخہ ہوتا ہے کہ share کے ذریعہ VCS
 - working style اور preferences ذاتی
2. Project-level: .claude/CLAUDE.md یا root CLAUDE.md
 - ہر لاگو project contributors تمام
 - ہوتا ہے کہ manage کے ذریعہ VCS
 - Coding standards, testing standards, architectural decisions
3. Directory-level: subdirectories میں CLAUDE.md
 - کہ ساتھ کام ہو تو لاگو ہوتا ہے کہ files کی directory جب اسی
 - conventions کہ اُس حصہ کہ مخصوص codebase

~/.claude/CLAUDE.md میں ملتی کیونکہ و project instructions کو team member عام غلطی: ایک نئے میں رکھی گئی تھیں (user-level) ~/.claude/CLAUDE.md کے بجائے (project-level)

5.2 @path Syntax (File Imports)

و جاتی configuration modular کر سکتا ہے، جس سے refer کے ذریعہ @path کو files بیرونی CLAUDE.md ہے:

Project CLAUDE.md

میں بیان کیہ گئے ہیں @./standards/coding-style.md
Coding standards
میں ہیں @./standards/testing-requirements.md
Test requirements
میں ہیں @package.json dependencies میں اور @README.md
Project overview

کے قواعد @path:

- (نہیں space کوئی) آئے file path کے فوراً بعد @
- Relative اور absolute paths دونوں supported ہیں
- Relative paths کے مطابق file اُس resolve کے میں جس میں import ہوتا ہے
- Maximum import nesting depth 5 ہے

شامل ہوتا ہے۔ ہیں standards میں صرف متعلقہ package کم ہوتی ہے اور duplication اس سے

5.3 .claude/rules/ Directory

کرنے کے organize کے حساب سے topic کو rules کا متبادل ہے، جو monolithic CLAUDE.md .claude/rules/ لیے استعمال ہوتا ہے:


```
.claude/rules/
testing.md          -- testing conventions
api-conventions.md  -- API conventions
deployment.md       -- deployment rules
react-patterns.md   -- React patterns
```

YAML frontmatter کے ساتھ `paths` conditional loading:

```
---
paths: ["src/api/**/*.ts"]
---
```

استعمال کریں `explicit error handling` کے ساتھ `async/await` کہ لیمہ API files
واپس کرہم `endpoint standard response wrapper` سے

```
---
paths: ["**/*.test.tsx", "**/*.test.ts"]
---
```

استعمال ہونہ چاہئیں `describe/it blocks` میں Tests
نہیں `hardcoding` استعمال کریں `Data factories`
استعمال کریں `test database` — نہ کریں `Database mock`

یہ کیسے کام کرتا ہے:

- کرتا match سہ `paths` pattern کے جو file edit ایسا Claude Code ہوتا ہے جب load صرف اس وقت Rule ہو
- نہیں ہوتے `rules load` بچتے ہیں — غیر متعلقہ `tokens` اور context اس سہ
- میں codebase files کرنے دیتے ہیں، چاہے `conventions apply` کے لحاظ سہ `file type` آپ کو `Glob patterns` (کے لیے بہت مفید tests) کے ہیں بھی ہوں

کب استعمال کریں `directory-level CLAUDE.md` بمقابلہ `.claude/rules/` والے `paths`:

- `.claude/rules/` with `paths` — جب `conventions` کئی directories میں بکھری files (tests, migrations) پر لاگو ہوں
- `Directory-level CLAUDE.md` — جب `conventions` کسی خاص directory اور کے ہیں ہوں وابستہ ہوں اور کے ہیں ضروری نہ ہوں

5.4 Custom Slash Commands اور Skills

skills کو (`.claude/commands/`) custom commands میں Claude Code version نوٹ: موجود
بناتے `commands` `/name` formats کر دیا گیا ہے دونوں unify کے ساتھ (`.claude/skills/`)
supported اب بھی format کا ذکر کرتی ہے — `.claude/commands/` میں امتحانی گائیڈ

نوٹ: میں `invoke` کے ذریعہ `/name` میں جو `Slash commands reusable prompt templates`

`.claude/commands/` format (legacy, supported):

```
.claude/commands/  
  review.md      -- /review -- standard code review  
  test-gen.md    -- /test-gen -- test generation
```

.claude/skills/ **format (current):**

```
.claude/skills/  
  review/SKILL.md -- /review -- frontmatter configuration  
  test-gen/SKILL.md
```

Project commands (`.claude/commands/` یا `.claude/skills/`):

- کرنے والے سب کے لیے دستیاب ہوتے ہیں repo clone میں محفوظ ہوتے ہیں اور VCS
- یقینی بناتے ہیں consistent workflows ٹیم میں

User commands (`~/.claude/commands/` یا `~/.claude/skills/`):

- انہیں ہوتے ہیں share کے ذریعے VCS جو commands ذاتی
- کے لیے workflows انفرادی

5.5 Skills — .claude/skills/

Skills advanced commands میں جو SKILL.md frontmatter کے ذریعے configure میں ہوتے ہیں:

```
---  
context: fork  
allowed-tools: ["Read", "Grep", "Glob"]  
argument-hint: "Path to the directory to analyze"  
---
```

کا تجزیہ کریں۔ code structure میں directory دی گئی
تیار کریں۔ report پر ایک architectural patterns اور Dependencies

Frontmatter parameters:

Parameter	Description
<code>context:</code> <code>fork</code>	نہیں کرتا pollute کو verbose output main session میں چلانا isolated subagent کو
<code>allowed-</code> <code>tools</code>	نہیں کرتا skill files delete مثلاً — security) دستیاب ہوں گے tools کے محدود کرتا ہے کون سے (سکے گی اگر اجازت نہ ہو
<code>argument-</code> <code>hint</code>	مانگنے کا اشارہ argument ہو تو invoke کے بغیر skill parameters جب

Skill **CLAUDE.md** کے استعمال کریں **مقابلہ**:

- **Skill** — task مخصوص کے لیے on-demand invocation (review, analysis, generation)
- **CLAUDE.md** — general standards اور conventions ہمیشہ لوڈ ہونے والے

Personal skills (~/ .claude/skills/):

- متاثر نہ ہونے teammates مختلف ناموں سے بنائیں تاکہ personal variants اپنی

5.6 Planning Mode بمقابلہ Direct Execution

Planning mode:

- نہ میں کرتا changes کرتا ؛ plan اور investigate صرف Model
- Codebase explore کرنا کرنا Read، Grep، Glob کرنا کرنا کرنا
- کرنا کرنا user approve تیار کرتا جسے implementation plan ایک
- safe exploration کے side effects بغیر

Planning mode کب استعمال کریں:

- changes (files درجنوں) بڑھانے
- Multiple plausible approaches (microservices: boundaries کیسے define ہوں؟)
- Architectural decisions (کیا framework کون سا؟ structure؟)
- Unfamiliar codebase (change پر سمجھنا ضروری ہے)
- Library migrations 45+ files کو متاثر کریں

Direct execution کب استعمال کریں:

- Single-file fixes ساتھ stack trace واضح
- شامل کرنا validation check ایک
- changes اچھی طرح سمجھ گئی، غیر مبہم

Combined approach:

1. Investigation اور design کرنا کرنا planning mode
2. User plan approve کرنا
3. Approved plan implement کرنا کرنا direct execution

Explore subagent — codebase explore کرنا کرنا specialized subagent:

- Verbose output کو main context سے isolate کرنا کرنا
- واپس کرنا summary صرف
- Multi-phase tasks میں context-window exhaustion روکنا

5.7 /compact Command

/compact context compress کرنا کرنا built-in command ہے:

- میں جگہ خالی کرنا context window کو summarize کرنا history چھپی
- Long investigation sessions میں verbose tool output context سے ہٹا کرنا جب
- Risk: exact numeric values، dates، اور specific details summarization میں گم ہو سکتا ہے

5.8 /memory Command

```
/memory sessions درمیان memory manage کرنا کے لیے built-in command:
```

- محفوظ کیے جا سکیں context اور notes، preferences، لیں کھولنا، تاکہ file editing (CLAUDE.md)
- بوتی load پر خود بخود startup کے پار برقرار رہتی اور Information sessions
- محفوظ context current work اور frequently used commands، user preferences، Project conventions، کرنے کے لیے مفید
- دوبارہ سمجھانے کا متبادل instructions میں وہی session پر

5.9 Claude Code CLI for CI/CD

-p (**--print**) flag:

```
claude -p "Analyze this pull request for security issues"
```

- Non-interactive mode: prompt process ☐ کرتا ، stdout پر print اور ☐ کرتا exit ☐ جاتا ☐
- User input کا انتظار نہ ☐ میں کرتا
- CI/CD pipelines میں ، Claude ☐ کا واحد درست طریقہ ☐

CI ☐ ☐ structured output:

```
claude -p "Review this PR" --output-format json --json-schema
'{"type":"object",...}'
```

- `--output-format json` — output کو JSON میں دیتا ہے
- `--json-schema` — output کو schema مطابق validate کرتا ہے
- `Result` کو automatically inline PR comments میں دے سکتا ہے

Session context isolation: Claude session میں کم مؤثر review کیا و، اکثر code generate جس نہ، Claude session و ی۔
 کر، کا امکان کم ونا challenge ساتھ رکھتا و اور اپنہ فیصلوں کو reasoning context اپنی (model ووتی و
 استعمال کریں، independent instance ک ل Review و)

Duplicate comments □ **بچھا** □ **review results context** □ **وقت** □ **پچھل** □ **review** □ **بعد دوبار** □ **commits** □ **س** □ **نڈا** □ **unresolved issues report** □ **کی** □ **دایت دیں** □ **صرف** □ **نڈا** □ **یا** □ **Claude** □ **میں شامل کریں اور**

5.10 fork_session اور Session Management

`--resume <session-name>` named session کو resume کرتا ہے

```
claude --resume investigation-auth-bug
```

- conversation □□ جاری رکھتا □□ saved context ساتھ بچھلی

- Long investigations پر پھیلی ہوئی ان کے لیے مفید sessions جو متعدد
- Risk: tool results stale ہوں تو files کے بعد session اگر پچھلی

fork_session shared context سے independent branch بناتا ہے:

```
Codebase investigation
|
fork_session
/      \
Approach A:  Approach B:
Redux       Context API
```

- کرتے ہیں context inherit تک forks branch point دونوں
- کرتے ہیں diverge اس کے بعد وہ آزادانہ طور پر
- Approaches compare یا strategies test کرنے کے لیے مفید

Resume نئی session کے بجائے نئی:

- Tool results stale ہوں (files بدل چکی ہوں)
- ہو گیا وہ context degrade کافی وقت گزر چکا ہو اور
- کرنے کے بجائے یہ بہتر ہے کہ "م نہ جو پایا اس کا مختصر خلاصہ یہ ہے": resume کے ساتھ tool data پرانے کیا جائے restart "... سے"

6 Prompt Engineering — Advanced Techniques

دستاویزات: [Prompt Engineering](#) | [Anthropic Cookbook](#)

6.1 Few-shot Prompting

Few-shot prompting میں 2–4 prompt دکھانے کے لیے expected behavior وہ طریقہ جس میں input/output examples شامل کیے جاتے ہیں

Few-shot text descriptions سے زیادہ مؤثر کیوں ہے:

- "وہ" کو کئی طریقوں سے سمجھا جا سکتا ہے precise جیسے "زیادہ instruction مہم"
- دکھاتا ہے decision logic اور expected format غیر مہم طور پر Example
- (دہراتا نہیں examples صرف) کرتا ہے generalize پر cases کو نئے Model pattern

Few-shot examples کی اقسام اور استعمال:

1. Ambiguous scenarios کے لیے examples:

Request: "My order is broken"

Action: Call get_customer -> lookup_order -> check status.

Rationale: "broken" damaged item میں درکار order details ہو سکتا ہے؛ آپ کو

Request: "Get me a manager"

Action: escalate_to_human call کریں فوراً

Rationale: Customer مانگ رہا ہے خود حل کرنے کی کوشش نہ کریں human واضح طور پر

2. Output formatting کے لیے examples:

Finding example:

```
{
  "location": "src/auth/login.ts:42",
  "issue": "SQL injection in the username parameter",
  "severity": "critical",
  "suggested_fix": "Use a parameterized query"
}
```

3. Acceptable problematic code کے لیے examples:

```
// Acceptable (flag نہ کریں):
const items = data.filter(x => x.active);

// Problem (flag کریں):
const items = data.filter(x => x.active == true); // Use strict equality ===
```

4. Different document formats سے extraction کے examples:

Document with inline citations:

"As shown in the study (Smith, 2023), the rate is 42%."

-> {"value": "42%", "source": "Smith, 2023", "type": "inline_citation"}

Document with bibliography references:

"The rate is 42%. [1]"

-> {"value": "42%", "source": "reference_1", "type": "bibliography"}

5. Informal measurements کے لیے examples:

Text: "about two handfuls of rice"

-> {"amount": "~100g", "original_text": "two handfuls", "precision": "approximate"}

Text: "a pinch of salt"

-> {"amount": "~1g", "original_text": "a pinch", "precision": "approximate"}

Few-shot اور non-standard measurement units میں مؤثر جو purely rule-based instructions کے لیے بہت متنوع ہوتی ہیں

Prompts میں format normalization rules: structured output کے لیے strict JSON schemas استعمال شامل کریں normalization rules میں prompt، کریں

Normalization:

- Dates: ہمیشہ ISO 8601 (YYYY-MM-DD); "yesterday" -> absolute date compute کریں
- Currency: numeric amount + currency code; "five bucks" -> {"amount": 5, "currency": "USD"}
- Percentages: decimal fraction; "half" -> 0.5

وہ values inconsistent ہیں مگر JSON syntactically کم ہیں۔ ان semantic errors اس سے

6.2 Explicit Criteria بمقابلہ Vague Instructions

Bad (vague):

Code comments کی accuracy چیک کریں۔
Conservative high-confidence findings report صرف رہیں –

Good (explicit criteria):

Comment کو problematic میں اُس صورت میں flag کریں جب:

1. Comment کا actual code behavior سے CONTRADICT ہو کرتا ہو
2. Comment کا حوالہ دہ variable یا function کسی غیر موجود
3. TODO/FIXME comment ایسے bug کی طرف اشارہ کرے جو کسی ایسے

Flag نہ کریں:

- کہ لحاظ سے پرانہ ہوں style جو صرف comments ایسے
- wording inaccuracies معمولی
- Missing comments (category یہ الگ)

Severity criteria examples کے ساتھ define کریں:

CRITICAL: User کے لیے runtime failure
Example: Payment process کرتے وقت NullPointerException

HIGH: Security vulnerability
Example: SQL injection, XSS, missing authorization checks

MEDIUM: Logic bug بغیر فوری impact کے
Example: Wrong sorting, off-by-one error

LOW: Code quality
Example: Duplication, suboptimal algorithm کے لیے data چھوٹے

6.3 Prompt Chaining

Prompt chaining میں توڑتا sequence کی focused steps کو ایک complex task

Step 1: auth.ts analyze کریں (صرف local issues)

-> Output: auth.ts میں issues کی list

Step 2: database.ts analyze کریں (صرف local issues)

-> Output: database.ts میں issues کی list

Step 3: Integration pass (cross-file dependencies)

-> Output: module boundaries پر issues

یہ کیوں اہم ہے:

- **Attention dilution** — جب files ایک ساتھ دیکھتا ہے تو کچھ files ایک ساتھ دیکھتا ہے، model سے بچاتا ہے — جب bugs miss کیے جاتے ہیں
- **Shallow commentary** — shallow commentary کر سکتا ہے اور باقی پر
- **Consistent analysis quality** — consistent analysis quality کر سکتا ہے
- **Cross-file interactions** — cross-file interactions الگ الگ کر سکتا ہے

کب استعمال کریں **dynamic decomposition** بمقابلہ **prompt chaining**:

- **Prompt chaining** — predictable, repeatable tasks (code review, file migrations)
- **Dynamic decomposition** — open-ended investigations ان subtasks execution کے دوران واضح ہوتے ہیں

6.4 “Interview” Pattern

Solution implement کرنے کے لیے Claude clarifying questions پوچھتا ہے:

Claude: "API کے لیے caching implement کرنے سے پہلے چند سوالات"

1. event-based یا TTL آپ پسند کرتے ہیں؟ cache invalidation strategy میں سے کون سی
2. stale data ہو تو کیا cache unavailable اگر قابل قبول ہے؟
3. Caching per-user یا global؟
4. Cache کے لیے expected data volume کیا ہے؟

یہ کب مفید ہے:

- Unfamiliar domain (fintech, healthcare, legal systems)
- Implications tasks (cache strategies, failure modes) واضح
- Viable approaches context میں بہترین انتخاب

6.5 Validation اور Retry-with-Feedback

extracted data validation fail کر کے:

Step 1: Document سے data extract کریں

Step 2: Validate کریں (Pydantic, JSON Schema, business rules)

Step 3: retry کریں کہ ساتھ context — error اگر:

- Original document
- Previous (incorrect) extraction
- Specific error: "Field 'total' = 150, but sum(line_items) = 145. Re-check values."

کب مؤثر ہوگا **Retry**:

- Format errors (date غلط format میں)
- Structural errors (field جگہ غلط)
- Arithmetic inconsistencies (model check دوبارہ کر سکتا ہے)

Retry گا کہ مدد نہ میں کرے گا:

- Information source document میں موجود ہے نہ میں
- Required context external (data کسی اور document میں کیا گیا)

Pydantic validation tool: Pydantic Python library جو schema-based data validation کے لیے استعمال ہوتی ہے۔ امتحان کے لیے اہم نکات یہ ہیں:

- **Structural validation:** types, requiredness, enum constraints JSON بعد کے code میں جانے دیے جاتے ہیں
- **Semantic validation:** custom validators business logic enforce کرتے ہیں (sum of items equals total! start_date < end_date)
- **Validate-retry loops:** Pydantic validation failure پر error message بنا کر Claude کو error context میں prompt ساتھ دوبارہ کریں
- **JSON Schema generation:** Pydantic models tool_use کے لیے JSON Schema generate کر سکتے ہیں۔ فراہم کرتا ہے single source of truth میں، جو ایک

6.6 Self-correction

Internal contradictions detect کا pattern:

```
{
  "stated_total": "$150.00",
  "calculated_total": "$145.00",
  "conflict_detected": true,
  "line_items": [
    {"name": "Widget A", "price": 75.00},
    {"name": "Widget B", "price": 70.00}
  ]
}
```

Model stated value اور computed value میں تو مختلف ہیں — اگر وہ conflict_detected آپ دونوں نکالتا ہے — اگر وہ مختلف ہیں تو تو Model stated value اور computed value میں تو تو discrepancy handle کرنا دیتا ہے

7 باب: Message Batches API

دستاویزات: [Message Batches](#)

7.1 Overview

Message Batches API کو asynchronous processing کے لیے requests کے batches submit کرنا دیتا ہے:

Attribute	Value
Savings	50% مقابلہ میں synchronous calls
Processing window	24 hours (latency SLA guarantee) زیادہ سے زیادہ
Multi-turn tool calling	Supported نہیں (request = ایک response)
Correlation	request اور response کو جوڑنے کے لیے custom_id field

7.2 Batch API بمقابلہ Synchronous API کے استعمال کریں

Task	API	Why
Pre-merge PR check	Synchronous	Developer 24 hours انتظار کر رہا ہے؛ قابل قبول نہیں
Overnight tech-debt report	Batch	Result 50% savings صبح تک چاہیے؛
Weekly security audit	Batch	50% savings فوری نہیں؛
Interactive code review	Synchronous	درکار response فوری
10,000 documents process کرنا	Batch	Bulk processing؛ savings ہیں

7.3 custom_id کا استعمال

```
{
  "custom_id": "doc-invoice-2024-001",
  "params": {
    "model": "claude-sonnet-4-6",
    "max_tokens": 1024,
    "messages": [{"role": "user", "content": "Extract data from: ..."}]
  }
}
```

آپ کو یہ کرنے دینا ہے custom_id:

- Result کو original document link سے
- Failure کو submit دوبارہ failed documents کی صورت میں صرف
- Successful documents کو process دوبارہ

7.4 Batch میں Failures کو Handle کرنا

1. 100 documents کا batch submit کریں
2. 95 succeed 5 fail (context limit exceeded) ہوں
3. Failures کو custom_id سے identify کریں
4. Strategy میں تقسیم کریں chunks کو long documents (مثلاً) بدلیں

کریں submit کو دوبارہ failed documents صرف اُن 5.5

7.5 SLA Planning

تک لگ سکتے ہیں hours کو 24 Batch API چاڑھ اور result میں hours اگر آپ کو 30

- Submission window: 30 - 24 = **6 hours**
- کریں submit پڑھ hours سے کم از کم 24 deadline کو Batches
- میں تقسیم کریں 4-hour windows سے لے کر 4 Frequent submissions

8 Task Decomposition Strategies

8.1 Fixed Pipelines (Prompt Chaining)

ہوتا ہے defined پڑھ step سے

Document -> Metadata extraction -> Data extraction -> Validation -> Enrichment -> Final output

کب استعمال کریں:

- Task structure predictable ہو (reviews ایک ہی template follow کریں)
- پڑھ سے معلوم ہوں steps تمام
- چاڑھ reproducibility اور stability آپ کو

8.2 Dynamic Adaptive Decomposition

ہوتا ہے ہیں generate کی بنیاد پر Subtasks intermediate results

- "Legacy codebase کے لیے tests add کریں"
- > Glob, Grep کریں structure map پڑھ
- کے ساتھ partial coverage کے، 2 tests بغیر modules: 3 ->
- > Prioritize: payments module شروع کریں (high risk)
- دریافت ہوئی dependency پر external API: کام کے دوران ->
- > Adapt: tests پڑھ سے mock add کریں external API لکھنے سے

کب استعمال کریں:

- Open-ended investigative tasks
- شروع میں معلوم نہ ہو scope جب مکمل
- پر منحصر ہو results کے step پچھلے step جب

8.3 Multi-pass Code Review

کے لیے pull requests والی 10+ files

```
Pass 1 (per-file): auth.ts analyze کریں -> local issues کی list
Pass 1 (per-file): database.ts analyze کریں -> local issues کی list
Pass 1 (per-file): routes.ts analyze کریں -> local issues کی list
...
Pass 2 (integration): files درمیان کہ relationships analyze کریں
-> Cross-file issues: inconsistent types, circular dependencies
```

کیوں خراب pass پر ایک سی 14 files:

- Attention dilution: shallow کچھ کی، deep analysis کی files کچھ
- Inconsistent comments: approve دوسری میں، pattern flag میں ایک file
- Missed bugs: cognitive overload واضح سی و سی errors کی وجہ سے

9 Escalation اور Human-in-the-Loop

9.1 Human کی طرف کب Escalate

Escalation triggers (rules واضح):

Situation	Action
Customer "get me a manager" واضح طور پر کہہ	کریں؛ حل کرنے کی کوشش نہ کریں escalate فوراً
Policy request نہ کرتی ہو cover کو	Escalate policy جب competitor price matching (مثلاً) کریں (و)
Agent پیش رفت نہ کر سکا	کریں escalate کے بعد attempts مناسب تعداد میں
Threshold financial operation اوپر	Escalate enforce، prompt کے ذریعہ hook ترجیحاً) کریں (نہیں)
Customer multiple matches تلاش کرتے وقت	مانگیں؛ انداز نہ لگائیں identifiers مزید

نہیں ہیں reliable trigger جو:

Unreliable method	Why it fails
Sentiment analysis	نہیں کرتا correlate سی mood case complexity کا
Model self-rated confidence (1–10)	کمزور calibration غلط ہو سکتا ہے؛ Model confidently
Automatic classifier	موجود نہ ہو و training data؛ ممکن Overengineering

9.2 Escalation Patterns

Immediate escalation:

Customer: "I want to speak to a manager"
Agent: [کرتا == escalate_to_human call فوراً]
NOT: "I can help with your issue, let me..."

Resolve escalation: کی کوشش کے بعد

Customer: "My refrigerator broke two days after purchase"
Agent: [کرتا == warranty replacement offer، چیک کرتا == order]
escalate -> مطمئن نہ ہو customer اگر

Nuanced escalation (acknowledge → resolve → reiteration پر escalate):

Customer: "This is outrageous, I'm very unhappy with the quality!"
Agent: [frustration acknowledge] "سمجھتا ہوں frustration میں آپ کی"
[resolution offer] "پیش کر سکتا ہوں refund یا replacement میں"
Customer: "No, I want to talk to someone!"
Agent: [customer دوبارہ insist کرہ -> immediate escalation]

کریں escalate دیں، اور صرف اسی وقت concrete solution کریں، پھر emotion acknowledge بنیادی اصول: پل۔
manager (ی۔) نہ کریں escalate کے پل۔ اطلاع پر dissatisfaction کی خواہش دہرائیں customer human جب
(مانگنے کے برابر نہیں ہیں)

Policy gap کے لیے escalation:

Customer: "Competitor X has this item 30% cheaper—give me a discount"
Policy: کرتی == price adjustments cover پر site صرف اپنی
Agent: [escalate – policy competitor price matching کو cover نہیں کرتی]

9.3 Structured Handoff Protocols

کو دینی چاہیے structured summary human agent پر Escalation:

```
{
  "customer_id": "CUST-12345",
  "customer_name": "Ivan Petrov",
  "issue_summary": "Refund request for a damaged item",
  "order_id": "ORD-67890",
  "root_cause": "Item arrived damaged; photos attached",
  "actions_taken": [
    "Verified customer via get_customer",
    "Confirmed order via lookup_order",
    "Offered a standard replacement – customer insists on a refund"
  ],
  "refund_amount": "$89.99",
  "recommended_action": "Approve a full refund",
  "escalation_reason": "Customer requested to speak with a manager"
}
```

دیکھنا summary تک رسائی نہیں ہوتی — صرف یہ full conversation transcript کو Human operator

ہونی چاہیے self-contained اس لیے یہ مکمل اور

9.4 Confidence Calibration اور Human Oversight

Data extraction systems □J □K:

1. **Field-level confidence scores:** model extracted field confidence score نکالنا
2. **Calibration:** labeled validation sets استعمال کر کے thresholds tune کریں
3. **Routing:**
 - High confidence + stable accuracy -> automated processing
 - Low confidence & ambiguous sources -> human review

Stratified random sampling:

- High-confidence extractions □ sample audit □ لی□ بھی باقاعدگی سد
- Aggregate 97% accuracy □ errors □□ چھپا سکتی □□ document type 40 لی□ خصوص
- Accuracy □□ analyze □□ حساب □□ field اور □□ document type □□، overall کو صرف

10 Error Handling میں Multi-agent Systems: پایب

10.1 Error Categories

Category	Examples	Retryable	Agent action
Transient	Timeout, 503, network failure	Yes	Exponential backoff retry ساتھ
Validation	Invalid input format, missing required field	No (input fix کریں)	Request modify کریں اور retry کریں

Business	Policy violation, threshold exceeded	No	پیش alternative کو سمجھائیں؛ User کریں
Permission	Access denied	No	Escalate کریں

10.2 Error-handling Anti-patterns

Anti-pattern	Problem	Correct approach
Generic status “search unavailable”	Coordinator decide نہیں کر سکتا کہ recover کیسے کرنا ہے	Error type, query, partial results, alternatives واپس کریں
Silent suppression (empty result = success)	Coordinator match سمجھتا ہے کہ failure ملا، حالانکہ	“no results” اور “search failure” میں فرق کریں
workflow پر پورا failure ایک abort کرنا	ضائع ہو جاتا ہے partial results تمام	Partial results کے ساتھ جاری رکھیں؛ gaps annotate کریں
Subagent میں infinite retries	Latency اور resources کا ضیاع	Local recovery (1–2 retries)، پھر coordinator تک propagate

10.3 Structured Subagent Error

```
{
  "status": "partial_failure",
  "failure_type": "timeout",
  "attempted_query": "AI impact on music industry 2024",
  "partial_results": [
    { "title": "AI Music Generation Report", "url": "...", "relevance": 0.8 }
  ],
  "alternative_approaches": [
    "Try a narrower query: 'AI music composition tools'",
    "Use an alternative data source"
  ],
  "coverage_impact": "Not covered: AI impact on music production"
}
```

کو فیصلہ کرنے کے لیے ضروری معلومات دیتا ہے coordinator

- Modified query کے ساتھ retry کریں؟
- Partial results استعمال کریں؟
- delegate کو subagent کسی اور کریں؟
- gap annotate کے بغیر جاری رکھیں اور اس section

10.4 Final Synthesis میں Coverage Annotations

Report: AI Impact on Creative Industries

Visual Art (FULL COVERAGE)

[research results]

Music (PARTIAL COVERAGE – search agent timeout)

[partial results]

⚠ Note: اس section کی coverage search agent timeout کی وجہ سے محدود ہے۔

Literature (FULL COVERAGE)

[research results]

11 Context میں Production Systems: باب 11 Management

11.1 Facts کو Separate Block میں Extract کریں

key facts (جو summarization کے دوران degrade ہو جاتی ہیں) پر انحصار کرنے کے بجائے conversation history میں extract میں structured block کو

```
=== CASE FACTS (کیا جائے update آئے fact جب بھی نیا) ===  
Customer ID: CUST-12345  
Order ID: ORD-67890  
Order Date: 2025-01-15  
Order Amount: $89.99  
Issue: Damaged item on delivery  
Customer Request: Full refund  
Status: Pending manager approval  
===
```

کیونکہ summarized history میں شامل کریں، چاہے prompt میں block ہو

11.2 Tool Results کو Trimming کرنا

کے لیے صرف 5 درکار ہیں current task واپس کرتا ہے مگر 40+ fields lookup_order اگر


```
# PostToolUse hook: رکھیں صرف relevant fields
@hook("PostToolUse", tool="lookup_order")
def trim_order_fields(result):
    return {
        "order_id": result["order_id"],
        "status": result["status"],
        "total": result["total"],
        "items": result["items"],
        "return_eligible": result["return_eligible"]
    }
```

کم noise ہوتی ہے اور context اس سے

11.3 Position-aware Input

Lost-in-the-middle effect رکھیں critical information کو ذہن میں رکھتے ہوئے:

```
[KEY FINDINGS – اوپر]
3 critical vulnerabilities ملیں...

[DETAILED RESULTS – درمیان]
=== File auth.ts ===
...
=== File database.ts ===
...

[ACTION ITEMS – آخر میں]
Priority: merge auth.ts vulnerabilities fix کریں.
```

11.4 Scratchpad Files

Long investigations میں agent key findings scratchpad file لکھ سکتا ہے:

```
# investigation-scratchpad.md
## Key findings
- PaymentProcessor in src/payments/processor.ts inherits from BaseProcessor
- refund() موتی ہے call سے places تین OrderController, AdminPanel, CronJob
- External PaymentGateway API limit: 100 req/min
- Migration #47 نہ refund_reason (NOT NULL) add 01-12-2024 کیا
```

scratchpad دوبارہ چلائے کہ بجائے agent discovery (میں session یا نئی) ہو جائے context degrade کر سکتا ہے

11.5 Context Subagents کو Delegate کرنا

Main agent: "payments module کی dependencies investigate کریں"

-> Subagent (Explore): 15 files read کرتا، imports trace کرتا

-> Returns: "Payments depends on AuthService, OrderModel, and the external PaymentGateway API"

Main agent: context 15 files میں رکھتا ہے line کہ بجائے ایک

Separate context layer: Multi-agent systems میں subagent context budget — میں کام کرتا ہے کہ طور پر separate context layer ایک Coordinator ملتی ہے کہ information کہ لی ضروری task اسد صرف اپنا کرتا context allocate کرتا ہے، اور global state store، کرتا subagent outputs aggregate subagent کام کرتا ہے: وہ اسد بھر دیتا ہے جو information کو ایسی agent window نہیں ہوتا، جہاں ایک "context leakage" اسد دوسروں کہ لی غیر متعلق ہو

Subagents constrained context budgets:

- Minimal context: specific task + ضروری data بھیجیں
- Subagent کو raw data dumps بجائے structured results کی ہدایت دیں
- اور کم distractions کا مطلب کم tools کریں — کم limit کو toolset کہ subagent اسد allowedTools context cost

11.6 Structured State Persistence (crash recovery کہ لی کہ)

کرتا ہے کہ export پر location ایک معلوم state اپنی agent

```
// agent-state/web-search-agent.json
{
  "status": "completed",
  "queries_executed": ["AI music 2024", "AI music composition"],
  "results_count": 12,
  "key_findings": [...],
  "coverage": ["music composition", "music production"],
  "gaps": ["music distribution", "music licensing"]
}
```

Coordinator resume پر ایک manifest load کرتا ہے کہ

```
// agent-state/manifest.json
{
  "web-search": "completed",
  "doc-analysis": "in_progress",
  "synthesis": "not_started"
}
```

کو محفوظ رکھنا Provenance: باب 12

12.1 Attribution Loss Problem

گم ہو سکتا ہے link "claim → source" کی جانچ میں، تو results summarize سے sources جب متعدد

Bad: "The AI music market is estimated at \$3.2B." (No source, no year.)

Good:

```
{
  "claim": "The AI music market is estimated at $3.2B.",
  "source_url": "https://example.com/report",
  "source_name": "Global AI Music Report 2024",
  "publication_date": "2024-06-15",
  "confidence": 0.9
}
```

12.2 Conflicting Data کو Handle کرنا

دیں values مختلف sources جب دو

```
{
  "claim": "Share of AI-generated music on streaming platforms",
  "values": [
    {
      "value": "12%",
      "source": "Spotify Annual Report 2024",
      "date": "2024-03",
      "methodology": "Automated classification"
    },
    {
      "value": "8%",
      "source": "Music Industry Association Survey",
      "date": "2024-07",
      "methodology": "Survey of 500 labels"
    }
  ],
  "conflict_detected": true,
  "possible_explanation": "Methodology اور time period کا فرق"
}
```

کو coordinator سے ساتھ محفوظ رکھیں اور attribution کو اندھا دھند منتخب نہ کریں۔ دونوں کو value کسی ایک فیصلہ کریں دیں۔

12.3 Correct Interpretation کے لیے Dates شامل کریں

سمجھ لیا جا سکتا ہے contradiction کو temporal differences کے بغیر Dates

Bad: "Source A says 10%, source B says 15%. Contradiction."

Good: "Source A (2023) says 10%, source B (2024) says 15%. Likely 5+ % growth."

12.4 Content Type مطابق Render کریں

میں نڈ ٹھونسیں format ر چیز کو ایک ی:

- Financial data -> tables
- News اور analysis -> prose
- Technical findings -> structured lists
- Time series -> chronological ordering

13 Claude Code Built-in Tools

13.1 Tool Selection Reference

Task	Tool	Example
تلاش کرنا files سڈ pattern نام	Glob	<code>**/*.test.tsx</code> , <code>src/components/**/*.ts</code>
File contents اندر search کرنا	Grep	Function name, error message, import
File مکمل پڑھنا	Read	Analysis کرنا file load کر لیا
بنانا file نیا	Write	Scratch سڈ file create کرنا
precise edit میں file موجود	Edit	Unique text match ذریعہ specific snippet replace کرنا
چلانا Shell command	Bash	git, npm, tests, build

13.2 Incremental Investigation Strategy

نڈ پڑھیں سمجھ بوجھ کو رفتہ رفتہ بنائیں files ایک ساتھ تمام:

- Grep: entry points تلاش کریں (function definition, export)
- Read: پڑھیں files ملندہ والی
- Grep: usages تلاش کریں (import, calls)
- Read: consumer files پڑھیں
- کریں repeat نہ مل جائے picture جب تک مکمل

13.3 Fallback: Edit بجائے Read + Write

و جائے fail کی وجہ سڈ Edit non-unique text match جب

1. Read — لوڈ کریں file content مکمل
2. Content کو programmatically modify کریں
3. Write — لکھ دیں updated version

امتحان دُومین نوٹس: حصہ II

1 ڈومین: Agent Architecture اور Orchestration (27%)

1.1 Autonomous Task Execution لیک ک Agentic Loops Design کرنا

Key knowledge:

- Agent loop lifecycle: Claude request `stop_reason` ("tool_use" بمقابلہ "end_turn") چیک کریں
 واپس کریں results کا لیٹر iteration کریں، اگلی tools execute کریں
- Tool results conversation history میں append کریں تاکہ model اگلا action کر سکے
 اور tool results کو history میں include کر سکے
- Model-driven decision making (Claude اگلا tool چنتا کرے گا) hard-coded decision trees بمقابلہ

Key skills:

- Flow control: جب `stop_reason = "tool_use"` جاری رکھیں اور loop `"end_turn"` پر رک جائیں
- Iterations کرنا میں context کو tool results `append` کرنا
- Anti-patterns `completion` `assistant text parse` کرنا، primary stopping mechanism `arbitrary iteration limits` پر

1.2 Multi-agent Systems (Coordinator–Subagent) Orchestrate کرنا

Key knowledge:

- Hub-and-spoke architecture: coordinator تمام inter-agent communication, error handling, اور routing کا مالک ہوتا ہے
- Subagents isolated context میں کام کرتے ہیں — coordinator کی history inherit نہیں کرتے
- Coordinator responsibilities: task decomposition, delegation, result aggregation, dynamic selection of subagents
- Coordinator کا overly narrow decomposition خطر ہے

Key skills:

- کم duplication کے درمیان تقسیم کریں تاکہ subagents کو Research coverage

- Iterative refinement loops implement کریں (coordinator synthesis evaluate اور tasks re-route کریں)
- Observability تمام communication coordinator کے ذریعے route کے لیے تمام

1.3 Subagent Calls, Context Passing, اور Spawning Configure کرنا

Key knowledge:

- Task tool subagents spawn؛ coordinator کے allowedTools میں "Task" ہونا چاہیے
- Subagent context prompt میں explicitly؛ ہونا چاہیے
- AgentDefinition configuration: descriptions, system prompts, tool constraints
- Alternatives explore کے لیے fork_session کے ذریعے session management

Key skills:

- Previous agents کے full outputs subagent prompt میں شامل کریں
- Context pass کو separate کو metadata اور data کرتے وقت
- Structured formats کے لیے parallel subagents spawn کے ذریعے Task calls میں متعدد coordinator turn ایک
- Coordinator prompts goals اور quality criteria، step-by-step instructions، طور پر لکھیں

1.4 Enforcement اور Handoff Patterns ساتھ Multi-step Workflows Implement کرنا

Key knowledge:

- Workflow ordering کے لیے programmatic enforcement (hooks, preconditions) اور prompt guidance کے درمیان فرق
- Deterministic guarantees (مثلاً مالی operations، identity verification)، prompts، درکار ہونے والے کافی ہیں
- Escalation کے دوران structured handoff protocols (customer ID, reason, recommended action)

Key skills:

- مکمل ہونے والے steps کریں جب تک کہ downstream calls کو block نہ کر دے (مثلاً process_refund block کریں، verified ID کے get_customer مثلاً)
- Multi-aspect customer requests کے items کو الگ
- Human کو escalate کے وقت structured summaries produce کریں

1.5 Tool Calls Intercept اور Agent SDK Hooks

Key knowledge:

- Hook patterns (مثلاً PostToolUse) tool results کو model کے consume کے لیے intercept کرنے کے لیے

- Hooks outgoing calls intercept ☐ کریں ☐ compliance rules enforce ☐ (مثلاً threshold اوپر refunds سدا کرنا)
- Hooks **deterministic guarantees** ☐ جبکہ ☐ prompt instructions **probabilistic compliance** دیتی ☐ ہیں ☐

Key skills:

- **PostToolUse** hooks **سب** data formats normalize کریں (Unix timestamps, ISO 8601, numeric status codes)
- Policy-violating actions block **لی** **ک** **ک** interception hooks اور escalation استعمال کریں اور redirect کریں
- منتخب کریں hooks **ک** بجائے **پ** **ی** **و** تو **guaranteed compliance** کو **business rules** جب

1.6 Complex Workflows Task Decomposition Strategies

Key knowledge:

- **Fixed pipelines** (prompt chaining) □ **dynamic adaptive decomposition** (intermediate results پر بنیاد کی)
- Prompt chaining: sequential steps □ (integration pass) (پھر analyze کو الگ □ file)
- Adaptive investigation plans □ (subtasks generate کی بنیاد پر discovered information جو)

Key skills:

- Predictable multi-aspect reviews □ ک prompt chaining؛ open-ended investigations □ لی dynamic decomposition
- Large code reviews کو per-file analysis + separate cross-file integration pass میں تقسیم کریں
- Open-ended tasks کو degrade □ لی□ لی structure map پھر prioritized plan بنائیں

1.7 Session State, Resuming, اور Forking

Key knowledge:

- Named sessions continue `--resume <session-name>` کرنا کے لیے
- Shared context `fork_session` بنانا کے لیے independent investigation branches سے
- Resume بتانا کی اہمیت file changes کو agent کو وقت
- Structured summary `reliable` زیادہ سے زیادہ `resuming` کے ساتھ `session` کے ساتھ نئی

Key skills:

- Named investigation sessions continue `--resume` کریں
- Approaches parallel compare `fork_session` کریں
- Resuming (context `current` اور نئی `session` شروع کریں) (results stale ہیں) `fork_session` کریں

5.10 fork_session اور Session Management

کرتا --resume <session-name> named session کو resume

```
claude --resume investigation-auth-bug
```

- جاری رکھتا conversation کے ساتھ پچھلی saved context
- پر پھیلی ہوں ان کے لیے مفید sessions جو متعدد Long investigations
- Risk: tool results stale بدل چکی ہوں تو files کے بعد session اگر پچھلی

fork_session shared context سے independent branch بناتا

```
Codebase investigation
  |
  fork_session
  /      \
Approach A:  Approach B:
Redux       Context API
```

- کرتا ہیں context inherit تک forks branch point دونوں
- کرتا ہیں diverge اس کے بعد آزادانہ طور پر
- کرنے کے لیے مفید strategies test کرنے یا Approaches compare

Resume نئی session کے بجائے نئی

- Tool results stale ہوں (files بدل چکی ہوں)
- و گیا ہو context degrade کافی وقت گزر چکا ہو اور
- کرنے کے بجائے ہو بہتر ہو کہ "م نہ جو پایا اس کا مختصر خلاصہ ہو" resume کے ساتھ tool data پرانے کیا جائے restart "... restart سے

2 Tool Design اور MCP Integration (18%) ڈومین

2.1 Clear Descriptions کے ساتھ Tool Interfaces Design کرنا

Key knowledge:

- Tool descriptions minimal descriptions کرتا ہے؛ LLM tools select میں جن سے mechanism و بنیادی unreliable selection دیتی
- Input formats, example queries, edge cases, اور applicability boundaries کی اہمیت شامل کرنے
- Ambiguous یا overlapping descriptions misrouting میں سبب بنتی
- System prompt wording tools کے associations کے ساتھ غیر ارادی بنا سکتی

Key skills:

- کریں distinguish سے واضح طور پر similar alternatives کو tool لکھیں جو ر descriptions ایسی

- Functional overlap (مثلاً) `analyze_content` -> `extract_web_results` tools rename کریں ختم کرنے کے لیے
- واضح input/output contracts میں تقسیم کریں جن کے specialized tools کو General-purpose tools

2.2 MCP Tools کے Structured Error Responses Implement کرنا

Key knowledge:

- MCP tool responses میں `isError` flag
- **Transient errors** (timeouts), **validation errors** (bad input), **business errors** (policy violations), اور **access/permission errors** کے درمیان فرق
- Generic errors ("Operation failed") میں recovery decisions روک دیتے ہیں صحیح
- Retryable اور non-retryable errors میں فرق

Key skills:

- `errorCategory` (transient/validation/permission), `isRetryable` اور human-readable message جیسی structured metadata واپس کریں
- Business-rule violations کے ساتھ user-facing explanations کے لیے واضح `retryable: false` استعمال کریں
- Transient failures کے لیے subagents میں local recovery صرف وہ errors propagate کریں؛ صرف وہ حل نہ کر سکیں
- Access failures (retry decision) اور valid empty results (no matches) میں فرق کریں

2.3 Agents میں Tools Allocation اور `tool_choice` Configure کرنا

Key knowledge:

- کم کرتی tool selection reliability (مثلاً 18 کے بجائے 4-5) tools بڑھاتے ہیں
- Specialization کے لیے agents رکھنے والے tools سے باہر
- Scoped tool access: cross-role utilities + role-relevant tools صرف
- `tool_choice: "auto"`, `"any"` اور forced tool selection (`{"type": "tool", "name": "..."}`)

Key skills:

- تک محدود رکھیں relevant tools صرف subagent کے
- General tools کو constrained alternatives سے بدلیں (مثلاً `fetch_url` -> `load_document`)
- یقینی tool call کے بجائے text answer استعمال کریں تاکہ `tool_choice: "any"`
- Specific tool force execution order assured کریں تاکہ

2.4 MCP Servers اور Claude Code میں Integrate کرنا

Key knowledge:

- MCP server scope: user کے لیے experiments بمقابلہ (`.mcp.json`) project ٹیموں کے لیے (`~/claude.json`)
- Secrets management کے لیے `.mcp.json` میں environment variable substitution (مثلاً `${GITHUB_TOKEN}`)
- available ہوتے ہیں اور ایک ساتھ discover پر tools connection کے connected MCP servers تمام ہیں
- MCP resources بطور “content catalogs” (task summaries, database schemas) exploratory tool calls کم کرتے ہیں

Key skills:

- Shared MCP servers کو project `.mcp.json` میں env-var-based tokens ساتھ configure کے کریں
- Personal/experimental servers کو `~/claude.json` میں رکھیں
- Standard integrations کے لیے community MCP servers کو custom servers پر ترجیح دیں

2.5 Built-in Tools (Read, Write, Edit, Bash, Grep, Glob) منتخب اور Apply کرنا

Key knowledge:

- **Grep**: file contents اندر search (function names, error messages, imports)
- **Glob**: name/extension patterns سے files تلاش کرنا
- **Read/Write**: full-file operations؛ **Edit**: unique text matches کے ذریعے precise changes
- Read + Write واپس جائیں تو fail کی وجہ سے Edit non-unique matches اگر

Key skills:

- Content search کے لیے Glob کے لیے pattern-based discovery اور Grep کے لیے
 - Read کرنے کے لیے flows trace پھر، Grep کے لیے entry points: سمجھ بوجھ رفتہ رفتہ بنائیں
 - Wrapper modules کے ذریعے function usage trace کریں
-

3 اور Claude Code Configuration ڈومین: Workflows (20%)

3.1 Hierarchy, Scope, اور Modular Organization کے ساتھ CLAUDE.md Configure کرنا

Key knowledge:

- CLAUDE.md hierarchy: user (`~/ .claude/CLAUDE.md`), project (`.claude/CLAUDE.md` یا root `CLAUDE.md`), اور directory-level (subdirectories میں `CLAUDE.md`)
- User-level settings میں `user` اور `project` کے درمیان فرق ہے۔ `user` صرف ایک `CLAUDE.md` ہے، جبکہ `project` `CLAUDE.md` کے ذریعے `VCS` پر لاگو ہوتا ہے۔
- External files refer کرنا `@path` syntax (مثلاً `@./standards/coding-style.md`) تاکہ `CLAUDE.md` modular بن سکے۔
- Monolithic `CLAUDE.md` بجائے `topic-focused rule files` کے لیے `.claude/rules/` directory

Key skills:

- Hierarchy issues diagnose کریں (team member کو instructions دینے میں) اور `project-level` میں `user-level` سے فرق کریں۔
- `@path` کرنا `standards selectively include` میں `CLAUDE.md` کے package کو `@./standards/testing.md` استعمال کریں۔
- `CLAUDE.md` کے متعدد `files` (`testing.md`, `api-conventions.md`, `deployment.md`) کو `.claude/rules/` میں تقسیم کریں۔

3.2 Custom Slash Commands اور Skills بنانا اور Configure کرنا

Key knowledge:

- `~/ .claude/commands/` بمقابلہ `.claude/commands/` میں **Project commands** (VCS کے ذریعے shared) اور **user commands** میں `~/ .claude/commands/`
- `.claude/skills/` میں SKILL.md frontmatter: `context: fork`, `allowed-tools`, `argument-hint`
- `context: fork` skill کو isolated subagent context تاکہ `main session` pollute نہ ہو۔
- Personal skill variants `~/ .claude/skills/` میں رکھ سکتے ہیں۔

Key skills:

- Project slash commands `.claude/commands/` میں رکھیں تاکہ پوری team حاصل کرے۔
- Verbose output کے لیے `skills isolate` استعمال کریں `context: fork`۔
- Skill کے `tools` کے لیے `allowed-tools` محدود کرنا۔
- Required parameters کے لیے `argument-hint` مانگنا۔

- (independent) کب sequentially اور (interdependent) میں کب دیں message ایک issues تمام

Key skills:

- Transformation requirements 3–2 لیجئے کہ concrete input/output examples فراہم کریں
- Implementation expected behavior, edge cases اور performance requirements کے ساتھ test sets بنائیں
- Design aspects (cache invalidation, failure modes) کے لیے interview pattern سامنے لائیں
- Edge cases کے لیے sample inputs اور expected outputs کے ساتھ concrete test cases دیں

3.6 Claude Code کو CI/CD Pipelines میں Integrate کرنا

Key knowledge:

- Automated pipelines میں non-interactive mode `-p` (یا `--print`) flag
- CI میں structured output `--output-format json` اور `--json-schema`
- CLAUDE.md project context (testing standards, review criteria) فراہم کرتا ہے
- Session context isolation:** code generate والی same session review میں کم مؤثر ہوتی ہے

Key skills:

- Interactive input پر hang نہ لیں۔ CI کو Claude Code میں -p کے ساتھ چلائیں
- Structured results (مثلاً inline PR comments) کے لیے --output-format json + --json-schema استعمال کریں
- new/unfixed issues (صرف) شامل کریں review results کرتے وقت پچھلے run کے بعد دوبارہ commits نہ رپورٹ کریں
- Test generation quality کے لیے available fixtures اور testing standards میں CLAUDE.md سے متاثر نہ ہونے کو یقینی بنائیں
- style نہ ہو اور duplication میں شامل نہ کریں تاکہ context کو existing test files سے متاثر نہ ہو اور tests generate نہ ہوں۔

4 ڈومین: Prompt Engineering اور Structured Output (20%)

4.1 Accuracy ☐ Prompts ☐ ساتھ Explicit Criteria ☐ تر کرنے کے لیے ☐ Design کرنا

Key knowledge:

- Explicit criteria vague instructions (مثلاً “flag comments only when they contradict code” “check comment accuracy”)
- “be more conservative” generic guidance concrete categorical criteria

- درست high false-positive rates میں categories پر اثر انداز ہوتے ہیں: کچھ False positives developer trust کم کر دیتی ہیں trust پر بھی categories

Key skills:

- Review criteria define کرنا (minor style) ignore اور کیا (bugs, security) کرنا report کریں: کیا
- High false-positive rates والی categories طور پر disable عارضی
- کرنا explicit severity criteria define کے ساتھ code examples کے لیے level پر

4.2 Output Consistency Few-shot Prompting بہتر کرنے کے لیے استعمال کرنا

Key knowledge:

- Few-shot examples consistently formatted, actionable output کا سب سے مؤثر method پیدا کرنے کا سب سے
- Few-shot cases (tool selection, test coverage gaps) کو دکھا سکتا ہے
- Few-shot model میں defaults میں مدد دیتا ہے، صرف generalize پر patterns کو نئے Few-shot model
- Few-shot extraction tasks میں hallucinations کو کم کر سکتا ہے

Key skills:

- Ambiguous scenarios کے لیے targeted examples کے ساتھ 4–2 rationale کے لیے
- Output format (location, issue, severity, suggested fix) شامل کریں examples دکھانے والے
- میں فرق دکھائیں real issues اور acceptable code patterns دیں جو examples ایسے
- دیں examples کے extraction سے درست documents والے structures مختلف

4.3 JSON Schemas کے ساتھ tool_use اور Structured Output کرنا Enforce

Key knowledge:

- JSON syntax errors کی ضمانت دینے اور tool_use with JSON Schemas schema-conformant output طریقہ کے سب سے reliable کرنے کا سب سے
- کرنی ہوتی tool call میں اسے لازماً "any" واپس کر سکتا ہے؛ model text میں tool_choice: "auto" منتخب کرتی ہے forced selection specific tool؛
- Strict JSON Schemas syntax errors سے روکتیں semantic errors ختم کرتی ہیں مگر (totals؛ میں ملے؛ values غلط fields غلط)
- Schema design: required vs optional fields؛ enums کے ساتھ "other" + detail string extensibility کے لیے

Key skills:

- JSON Schemas کے ساتھ extraction tools define کریں اور results tool_use کے ساتھ data parse کریں
- استعمال کریں tool_choice: "any" یقینی بنانے کے لیے structured output کے ساتھ تو schemas متعدد
- Specific tool call force کریں: tool_choice: {"type": "tool", "name": "extract_metadata"}
- Source information میں fields کے لیے values fabricate نہ ہونے کی صورت میں optional/nullable رکھیں

- Extensible categorization کے لیے "unclear" اور "other" جیسے enum values + detail fields استعمال کریں

4.4 Extraction Quality Validation, Retries, Feedback Loops Implement کرنا

Key knowledge:

- Retry-with-error-feedback: correction guide کے لیے retry prompt میں concrete validation errors شامل کریں
- فوائد و ہونے والے retries میں موجود کمی نہ ہو تو information source اگر
- Feedback loop design: finding کو trigger کرنے والا pattern (detected_pattern) کریں track
- Semantic errors (totals reconcile ہونے والے میں) syntax errors (جو tool_use سے address ہونے والے ہیں)

Key skills:

- Original document, incorrect extraction, اور specific validation errors کے ساتھ follow-up prompts دیں
- تو اس کی شناخت کریں (میں سے و external document صرف required info کے فوائد و retry جب
- False positives analyze کے لیے findings میں detected_pattern fields شامل کریں
- Discrepancies detect کے لیے calculated_total اور stated_total extract دونوں میں self-correction design کریں

4.5 Efficient Batch Processing Strategies Design کرنا

Key knowledge:

- Message Batches API: 50% savings, 24-hour تک processing window, latency SLA guarantee ہیں
- Batch processing non-blocking tasks (overnight reports, audits) اور blocking tasks کے لیے مناسب ہیں (pre-merge checks) کے لیے نہیں
- Batch API میں single request کے multi-turn tool calling support ہیں کرتا
- custom_id fields batch کے request/response correlate ہیں کرتی

Key skills:

- Blocking checks کے لیے synchronous API اور overnight/weekly workloads کے لیے Batch API استعمال کریں
- SLA needs مطابق batch submission cadence plan کریں (24-hour guarantee مثلاً 30) processing 4-hour windows کے ساتھ
- Failed documents (identified by custom_id) کو دوبارہ submit کے failures handle کریں
- Large-scale processing کے لیے sample کے ساتھ prompts iterate کریں

4.6 Multi-instance اور Multi-pass Review Architectures Design کرنا

Key knowledge:

- Self-review limitations: model کا challenge ساتھ رکھنا اور اپنے فیصلوں کو reasoning context اپنی model امکان کم ہوتا ہے
- Independent review instances (generation context) subtle issues میں بہتر ہوتی ہیں (کم بغیر generation context)
- Multi-pass review: per-file local analysis + cross-file integration pass attention dilution سے بچانا

Key skills:

- Changes review استعمال second independent Claude instance کے بغیر generation context کر کے لے کر
- Multi-file reviews cross-file dataflow میں تقسیم کریں تاکہ per-file passes + integration passes کو analysis ہو سکے
- Self-rated confidence route طریقہ سے calibrated reviews استعمال کر کے verification passes کے ساتھ

5 Context Management اور Reliability (15%) ڈومین 5

5.1 Critical Information Conversation Context محفوظ رکھنا اور لی کرنا Manage کرنا

Key knowledge:

- Progressive summarization کے خطرات: numeric values, percentages, اور dates vague summaries میں بدل جاتے ہیں
- Lost-in-the-middle effect: models long inputs کے شروع اور آخر کو زیادہ reliable سے کر سکتے ہیں، لیکن درمیان کے findings miss ہیں
- Tool outputs relevance میں context کے مقابلہ میں (40+ fields جب جمع ہو سکتے ہیں) disproportionately میں
- Subsequent API requests کی full conversation history میں

Key skills:

- Transactional facts کو summarized history کے بائیں persistent “case facts” block میں نکالیں
- Verbose tool outputs کو relevant fields تک trim کریں
- Key findings کو aggregated data کے شروع میں explicit section headings کے ساتھ رکھیں
- Subagents کے structured outputs میں metadata (dates, sources) شامل کروائیں

5.2 Effective Escalation Patterns Design اور Ambiguity کرنا Resolve کرنا

Key knowledge:

- Suitable escalation triggers: human کی explicit request, policy gaps/exceptions, پیش رفت نہ ہو پانا
- Immediate escalation (explicit request) attempt-to-resolve (agent scope اندر) بمقابلہ
- Sentiment analysis اور model confidence self-ratings case complexity کے unreliable proxies ہیں
- Multiple customer matches کے heuristic guessing کے بجائے additional identifiers چائیں

Key skills:

- System prompt میں explicit escalation criteria few-shot examples کے ساتھ دیں
- Human کی explicit request کے execute کے فوراً investigation کو بغیر اضافی
- Escalate ہو تو silent یا ambiguous کے لیے specific request کسی policy جب
- Tool results میں multiple matches ہوں تو additional identifiers مانگیں

5.3 Multi-agent Systems میں Error Propagation Strategies Implement کرنا

Key knowledge:

- Structured error context (failure type, query, partial results, alternatives) coordinator کو smarter recovery دیتا ہے
- Access failures (timeouts retry decision میں) اور valid empty results (no matches) میں فرق کریں
- Generic error statuses ("search unavailable") coordinator کے valuable context چھپا دیتے ہیں
- Silent suppression کے anti-patterns کرنا دونوں workflow abort پر پورا failure یا ایک

Key skills:

- Structured error context میں failure type, کیا گیا attempt, partial results, possible alternatives واپس کریں
- Access failures کے الگ کریں valid empty results
- Transient failures کے لیے subagents میں local recovery کے صرف non-recoverable errors partial results کے ساتھ propagate کریں
- Synthesis میں coverage annotate طرح کیا اچھی اور کے ان supported کریں: کیا اچھی طرح

5.4 Large Codebases Investigate وقت Context Efficiently Manage کرنا

Key knowledge:

- Long sessions میں context degradation: model unstable answers اور مخصوص classes دینے لگتا ہے
- Scratchpad files key findings کو context boundaries میں پار محفوظ رکھتے ہیں
- Subagents کو delegate کے verbose discovery output isolate کے ہوتے جاتی ہیں

- Structured state persistence crash recovery ممکن بناتی

Key skills:

- Specific questions میں رکھیں high-level coordination main agent spawn subagents کے لیے
- Key findings استعمال کریں scratchpad files کے لیے refer محفوظ رکھنے اور بعد میں
- Long investigations میں summarize key findings کے لیے spawn subagents کے phase اگلا
- استعمال کریں /compact کم کرنے کے لیے context usage کے دوران

5.5 Human Oversight اور Confidence Calibration کے ساتھ Workflows Design کرنا

Key knowledge:

- Aggregate metrics (97% overall accuracy) specific document types یا fields پر کمزوری چھپا سکتے ہیں
- Stratified random sampling high-confidence extractions میں error rates measure کرتا
- Field-level confidence calibration labeled validation sets کے ذریعے
- Automation accuracy validate کے حساب سے field segment اور document type پر

Key skills:

- New error patterns detect stratified random sampling implement کرنے کے لیے
- Stable performance validate accuracy analyze کے حساب سے field اور document type کے لیے
- Field-level confidence scores output review thresholds calibrate کے ذریعے labeled data کریں اور
- Low-confidence یا ambiguous-source extractions human review route کی طرف

5.6 Multi-source Synthesis میں Provenance Preserve کرنا اور Uncertainty Handle کرنا

Key knowledge:

- Summarization محفوظ نہ رہیں mappings “claim → source” کہو جاتی اگر attribution کے دوران
- Aggregation برقرار رہنی چاہئیں structured mappings کے دوران
- Conflicting statistics conflict annotate کے ساتھ attribution منتخب کرنے کے بجائے value ایک arbitrarily کو handle کریں
- Temporal differences شامل کریں publication/collection dates سمجھنے سے بچنے کے لیے contradiction کو

Key skills:

- Subagents کروائیں output mappings (“claim → source”) (URL, document name, quotes) سے
- Reports structure میں الگ disputed ones اور stable findings کو
- Conflicting values coordinator کے لیے reconciliation کے ساتھ محفوظ رکھیں اور annotations کو
- Correct temporal interpretation شامل کریں publication dates کے لیے

- Content type مطابق render کریں: financial data tables میں، news prose میں، technical findings میں structured lists میں

Claude Certified Architect — Foundations Certification

مطالعہ گائیڈ (سرکاری امتحانی گائیڈ کی بنیاد پر)

تعارف

Claude Certified Architect — Foundations سرٹیفیکیشن اس بات کی تصدیق کرتی ہے کہ ایک ماہر Claude-based trade-off حل بنانے کے وقت درست Claude Code، Claude Agent SDK، Claude API، اور Model Context Protocol (MCP) بنیادی ٹیکنالوجیز جن کے بنیادی علم کو جانچتا ہے — یعنی وہ بنیادی ٹیکنالوجیز جن کے بنیادی علم کو جانچتا ہے — کے ساتھ پروڈکشن ایپلیکیشنز تیار کی جاتی ہیں۔

بنانا agentic systems امتحان کے سوالات حقیقی دنیا کے منظرناموں پر مبنی ہوتے ہیں: کسٹمر سپورٹ کے لیے، multi-agent research pipelines میں شامل کرنا CI/CD کو Claude Code، ڈیزائن کرنا developer productivity tools نکالنا structured data بنانا، اور غیر ساختہ دستاویزات سے tools

هدف امیدوار

کرتا ہے آپ ship کے ساتھ پروڈکشن ایپلیکیشنز ڈیزائن اور Claude کے جو solution architect مثالی امیدوار ایک کے پاس کم از کم 6 ماہ کا عملی تجربہ ہونا چاہیے:

- Claude Agent SDK — multi-agent orchestration، subagents کو delegate کرنا، tool integration، lifecycle hooks
- Claude Code — CLAUDE.md، MCP servers، Agent Skills، planning mode
- Model Context Protocol (MCP) — backend integration کے لیے tools اور resources
- Prompt engineering — JSON schemas، few-shot examples، data extraction templates
- Context windows — لمبی دستاویزات، multi-agent context passing
- CI/CD pipelines — automated code review، test generation
- Escalation and reliability — error handling، human-in-the-loop

امتحانی فارمیٹ

پیرامیٹر	قدر
سوال کی قسم	Multiple choice (1 درست 4 میں سے)

اسکورنگ	100–1000 scale, passing score 720
Guessing penalty	نہیں (ہر سوال کا جواب دیں!)
Scenarios	8 4 میں سے (randomly selected)

امتحانی مواد: 5 ڈومینز

ڈومین	وزن
1. Agent architecture and orchestration	27%
2. Tool design and MCP integration	18%
3. Claude Code configuration and workflows	20%
4. Prompt engineering and structured output	20%
5. Context management and reliability	15%

امتحانی منظر نامہ

Scenario 1: Customer Support Agent

ایک agent آپ کو Claude Agent SDK کے ساتھ returns, billing disputes, اور account issues کے ساتھ agent MCP tools (`get_customer`, `lookup_order`, `process_refund`, `escalate_to_human`) کے ساتھ 80% first-contact resolution کے ساتھ 80% استعمال کرتا ہے۔

Scenario 2: Claude Code کے ساتھ Code Generation

code generation, refactoring, debugging, documentation کے ساتھ Claude Code کے ساتھ development کے ساتھ آپ کو custom slash commands اور CLAUDE.md configuration کے ساتھ integrate اور planning mode کے ساتھ استعمال کو سمجھنا کے ساتھ

Scenario 3: Multi-Agent Research System

coordinator agent specialized subagents کے ساتھ tasks: web research, document analysis, synthesis, اور report generation کے ساتھ citations کے ساتھ سسٹم کے ساتھ

Scenario 4: Developer Productivity Tools

agent engineers کے ساتھ unfamiliar codebases explore کے ساتھ boilerplate code اور routine tasks automate کے ساتھ MCP servers اور Built-in tools (Read, Write, Bash, Grep, Glob) کے ساتھ میں مدد دینا کے ساتھ

Scenario 5: Claude Code for Continuous Integration

Claude Code کو CI/CD pipeline میں ضم کریں تاکہ automated code reviews، test generation، pull request feedback اور pull request feedback کم سے کم false positives بننے چاہئیں کہ Prompts حاصل ہو request feedback

Scenario 6: Structured Data Extraction

کرتا ہے، validate کے ذریعے JSON schemas کو output، سسٹم غیر ساختہ دستاویزات سے معلومات نکالتا ہے اور درست طور پر سنبھالنے چاہئیں کہ edge cases برقرار رکھتا ہے اس high accuracy اور

Scenario 7: Conversational AI Architecture Patterns

multi-turn conversational systems میں جن میں context window management، turns متعدد، memory strategies، execution محفوظ، tool design کے لیے instructions میں اور مہم یا متضاد، user inputs کو سنبھالنا شامل ہے

Scenario 8: Agentic AI Tools (امداد موجود نہیں — جاری مدد کریں)

میں شامل نہیں ہے، guide نہ دی لیکن ابھی تک اس candidates کی اطلاع امتحان دینے والے scenario اس میں share میں GitHub Issues کے سوالات دیکھیں، تو انہیں scenario اگر آپ نہ اصل امتحان میں اس شامل کر سکیں آپ کا تعاون اس شخص کی مدد کرے گا جو امتحان کی تیاری کر coverage تاکہ ہم مکمل رہے

نظریاتی بنیادیں: حصہ 1

یہ حصہ و بنیادی نظریہ بیان کرتا ہے جس کی آپ کو امتحان میں کامیابی کے لیے ضرورت ہے مواد کو topic کے مطابق — اس سے domains کے مطابق ترتیب دیا گیا ہے، نہ کہ امتحانی concepts اور technologies کی گہری سمجھ بھنی ہے

کی بنیادیں Claude API — Model Interaction: باب 1

دستاویزات: Messages API | Prompt Engineering

1.1 API Request Structure

Claude API میں عموماً Claude Messages API request پر کام کرتا ہے request-response model ایک شامل ہوتا ہے:

```
{
  "model": "claude-sonnet-4-6",
  "max_tokens": 1024,
  "system": "You are a helpful assistant.",
  "messages": [
    {"role": "user", "content": "Hi!"},
    {"role": "assistant", "content": "Hello!"},
    {"role": "user", "content": "How are you?"}
  ],
  "tools": [...],
  "tool_choice": {"type": "auto"}
}
```

۱۰:۰۰ م فیلڈز

- `model` — model selection (`claude-opus-4-6` , `claude-sonnet-4-6` , `claude-haiku-4-5`)
- `max_tokens` — response `توکنز میں زیادہ سے زیادہ`
- `system` — system prompt (model `کی تعریف`)
- `messages` — conversation history (**full history** `بھیجنا ضروری`)
- `tools` — definitions `کی available tools`
- `tool_choice` — tool selection strategy

1.2 Message Roles

استعمال کرتا □□ instructional role اور ایک conversational roles دو array messages

- `user` — user messages, tool results (ایک `user` role message کے اندر `tool_result` کی صورت میں بھیجے جاتے ہیں، ایک الگ content block)
- `assistant` — model responses (بھیجے وقت شامل ہونے والے history میں tool use requests (`tool_use` content blocks))
- `system` — top-level `system` field سے سیٹ کیا جا سکتا ہے (turn کے ذریعے سیٹ کیا جا سکتا ہے) یا (سے لاگو ہوتا ہے `turn`) اس نقطہ سے آگے) شامل کیا جا سکتا ہے inline کے طور پر `{"role": "system", ...}` میں `messages` (تابع — نیچے دیکھیں placement rules لاگو ہوتا ہے، مخصوص

کے طور پر user-role message کے طور پر نہیں بھیجا جاتا۔ ایک message والے role "tool" کو Tool results کے content block tool_result میں ایک content پر بھیج دیا جاتا ہے۔ جس کے شامل ہوتا ہے۔

```
{
  "role": "user",
  "content": [
    {
      "type": "tool_result",
      "tool_use_id": "toolu_01...",
      "content": "..."
    }
  ]
}
```

top-level کا طور پر ظاہر ہو سکتا ہے، نہ صرف role میں بھی ایک array messages براہ راست system کیے بغیر invalidate کو cached prefix کے system field top-level کے ذریعے اس کا مقصد parameter system placement rules شامل کرنا اس کے مخصوص instructions کے درمیان conversation:

- پر ختم ہونے والے server tool use یا (تو blocks tool_result بشمول وہ جس میں) user turn یا ایک assistant turn فوراً بعد آنا چاہیے۔
- ہونا چاہیے element کا آخری array سے پہلے آنا چاہیے یا assistant turn کسی
- ملتا error کے درمیان نہیں آ سکتا — ایسا کرنے پر 400 tool_result اور اس کے block tool_use کسی
- پہلے والوں پر اور بعد (کے درمیان شامل کیے گئے conversation بشمول) system messages بعد میں آنے والے پر فوقیت رکھتے ہیں system field top-level کے لیے turns

محفوظ state کے درمیان Model requests بھیجیں conversation history میں مکمل API request ام بات: ر آزاد ہوتی ہے call نہیں رکھتا؛ ر

1.3 stop_reason

Claude API response میں stop_reason کے جو بتاتا ہے کہ model ہوتا ہے کیوں رکا:

Value	Description	Action
"end_turn"	نہ جواب مکمل کر لیا Model	کو نتیجہ دکھائیں user
"tool_use"	چاہتا ہے Model tool call	واپس دیں result چلائیں اور tool
"max_tokens"	ختم ہو گئی Token limit	response truncated؛ limit؛
"stop_sequence"	مل گئی Stop sequence	کریں handle کے مطابق application logic

کرتے loop control ہیں — یہی signals سب سے اہم "end_turn" اور "tool_use" میں Agentic systems ہیں

1.4 System Prompt

متعین کرنا context اور behavioral rules جو instruction ایک خاص System prompt

- messages array الگ ہوتا؛ الگ system field کا حصہ نہیں ہوتا؛
- user messages پر فوقیت رکھتا ہے
- ہو کر پوری گفتگو میں لاگو رہتا ہے load ایک بار
- کی وضاحت کے لیے استعمال ہوتا ہے output format، اور role، constraints،

کو غیر ارادی طور پر متاثر کر سکتی ہے مثال tool selection wording کی system prompt: امتحان کے لیے اہم ضرورت سے زیادہ get_customer کو model کی تصدیق کریں جیسی ہدایت customer کے طور پر "میش استعمال کرنے پر لا جا سکتی ہے"


```
{
  "name": "get_customer",
  "description": "Finds a customer by email or ID. Returns the customer profile, including name, email, order history, and account status. Use this tool BEFORE lookup_order to verify the customer's identity. Accepts an email (format: user@domain.com) or a numeric customer_id.",
  "input_schema": {
    "type": "object",
    "properties": {
      "email": {"type": "string", "description": "Customer email"},
      "customer_id": {"type": "integer", "description": "Numeric customer ID"}
    },
    "required": []
  }
}
```

Tool description نکات:

- Minimal descriptions کا سبب بنتی selection غلط mechanism کا بنیادی tool selection کی Description ہیں
- edge cases، کیا input format، کیا کرتا، کیا واپس کرتا tool: میں یہ شامل کریں Description، اور یہ کب استعمال ہو
- Overlapping descriptions سے بچیں
- Built-in tools اور MCP tools overlap کو تو واضح بنائیں MCP tool

2.3 tool_choice


Value	Behavior	کب استعمال کریں
<code>{ "type": "auto" }</code>	Model خود طے کرتا	default عام
<code>{ "type": "any" }</code>	Model کرنی tool call کو لازماً ہوگی	structured output جب چاہیے
<code>{ "type": "tool", "name": "extract_metadata" }</code>	ہوگی call لازماً tool خاص	forced first step / order کی لیں

2.4 JSON Schemas for Structured Output

reliable لیں کا سبب structured output سے Claude استعمال کرنا `tool_use` کی سائنہ JSON schemas کی semantic correctness نافذ کرتا، مگر required structure کم کرتا اور syntax errors طریقہ سے ضمانت نہیں دیتا

Design اصول:

- رکھیں جو ہمیشہ ملنے چاہئیں fields required صرف وہ
- استعمال کریں nullable fields کی لیں missing data ممکنہ
- enum values جیسے "unclear" اور "other" information شامل کریں تاکہ



Coordinator task کو توڑتا ہے، subagents کے نتائج جوڑتا ہے، کام سونپتا ہے، منتخب کرتا ہے، errors handle کرتا ہے، جواب پہنچاتا ہے final تک user کو، اور

نہیں کرتا۔ inherit خود بخود parent history الگ ہوتا ہے؛ وہ context کا subagents کا ماحول:

3.4 Task Tool

Subagents Task tool کے ذریعے spawn کیے جاتے ہیں۔ Coordinator کے allowed_tools میں "Task" ہونا چاہیے۔

context passing: صحیح

- Task: "Analyze the document" کافی نہیں
- Task: "Analyze this document. Full text: ... Output schema: ..." درست ہے

Coordinator ایک response میں multiple Task s لے سکتا ہے، لہذا parallel subagents بھیج سکتا ہے،

3.5 Hooks

Hooks lifecycle کے مخصوص points پر work کیے جاتے ہیں۔

PostToolUse tool result کو model پہنچانے کے لیے normalize کر سکتا ہے:

```

@hook("PostToolUse")
def normalize_dates(tool_result):
    return normalized_result

```

PreToolUse policy violation block کر سکتا ہے:

```

@hook("PreToolUse")
def enforce_refund_limit(tool_call):
    if tool_call.name == "process_refund" and tool_call.args.amount > 500:
        return redirect_to_escalation(tool_call)

```

Critical business rules ہوتی ہیں۔ prompt instructions probabilistic ہوتے ہیں؛ hooks deterministic: یاد رکھیں۔

باب 4: Model Context Protocol (MCP)

4.1 MCP کیا ہے

MCP resource سے جوڑنا اس کے تین بنیادی Claude کو external systems جو open protocol ایک types ہیں:

1. **Tools** — actions کے functions
2. **Resources** — context data (documentation, schemas, catalogs)
3. **Prompts** — predefined task templates

4.2 MCP Servers

MCP server ایک process جو tools/resources expose کرتا ہے Connect پر tools discover ہوتا ہے۔ مطابقت استعمال ہوتا ہے۔ descriptions ہیں اور

4.3 Configuration

Project config (`.mcp.json`) کے لیے:

```
{
  "mcpServers": {
    "github": {
      "command": "npx",
      "args": ["-y", "@modelcontextprotocol/server-github"],
      "env": {"GITHUB_TOKEN": "${GITHUB_TOKEN}"}
    }
  }
}
```

User config سے آتی ہے۔ secrets environment variables میں ہوتی ہے؛ Project config version control (`~/.claude.json`) personal/experimental servers کے لیے ہوتی ہے۔

4.4 isError

MCP tool errors میں `isError: true` Generic errors کے بجائے structured error کو واپس کریں:

```
{
  "isError": true,
  "content": {
    "errorCategory": "transient",
    "isRetryable": true,
    "message": "The service is temporarily unavailable."
  }
}
```

4.5 Resources

Resources □ and data □ agent □ action □ □ پڑھ سکتا □: schemas, docs, content catalogs, summaries □ □ exploratory tool calls □ □ کم کرتا □

اور Claude Code — Configuration: باب 5 Workflows

دستاویزات: [Claude Code](#) | [Memory / CLAUDE.md](#) | [Skills](#) | [MCP](#) | [Hooks](#) | [Sub-agents](#) | [GitHub Actions](#) | [Headless](#)

5.1 CLAUDE.md Hierarchy

تین سطحوں پر سو سکتا Claude.md

- **User-level:** `~/ .claude/CLAUDE.md` — پر لاگو user صرف اسی
- **Project-level:** `.claude/CLAUDE.md` یا `root` `CLAUDE.md` — team کے لیے پوری
- **Directory-level:** subdirectories میں `CLAUDE.md` — folder conventions مخصوص

5.2 @path Syntax

و: config modular کی جا سکتے ہیں تاکہ external files refer @path میں CLAUDE.md

Coding standards @./standards/coding-style.md میں ہیں
Test rules @./standards/testing-requirements.md میں ہیں

5.3 .claude/rules/

conditional loading کے ذریعے paths کرتا ہے اور organize کے لحاظ سے topic کو rules/claude/rules/ دیتا ہے:

```
---
paths: ["src/api/**/*"]
---
```

استعمال کریں۔ explicit error handling اور async/await کے لیے API files

5.4 Commands اور Skills

`.claude/commands/` project commands کے لیے، جبکہ `~/claude/commands/` personal commands کے لیے۔
ملتی ہیں۔ skills کے ساتھ frontmatter میں `.claude/skills/` کے لیے۔

5.5 Skills اور context: fork

context: fork skill کو isolated context میں چلانا، allowed-tools سے tool access اور محدود کریں،
argument-hint سے required input مانگیں۔

5.6 Planning Mode

Planning mode کے لیے، بہترین unfamiliar codebases اور multiple approaches، تبدیلیوں architectural بڑی
کے لیے، بہتر changes کے واضح Direct execution اور واضح

5.7 /compact اور /memory

/compact سے context compress کرتا ہے، اور /memory سے notes اور preferences میں مدد دیتا ہے۔

5.8 Claude Code CLI for CI/CD

-p / --print non-interactive mode کے لیے استعمال ہوتا ہے:

```
claude -p "Analyze this pull request for security issues"
```

Structured output کے لیے --output-format json اور --json-schema استعمال کریں۔

باب 6: Prompt Engineering — Advanced Techniques

دستاویزات: [Prompt Engineering](#) | [Anthropic Cookbook](#)

6.1 Few-shot Prompting

Few-shot prompting میں 2–4 examples کے expected behavior کے لیے دکھایا جاتا ہے۔
vague instructions سے کم کرتا ہے example ambiguity زیادہ مؤثر کیونکہ

6.2 Explicit Criteria

decide severity کرنا، اور ignore کرنا، کیا flag دیں: کیا clear criteria بجائے vague instructions کرنا

6.3 Prompt Chaining

Complex task کو focused steps میں توڑیں: local analysis، integration pass، attention dilution کم کرتا

6.4 Interview Pattern

domain سامنے لاتا، خاص طور پر جب design ambiguity پوچھنا clarifying questions سے Claude unfamiliar

6.5 Validation and Retry

کریں retry کے ساتھ، specific validation error اور، original document، incorrect output، Extraction fail کو

6.6 Self-correction

کریں discrepancy handle کو تو conflict دونوں نکال: Model stated value اور calculated value

7: Message Batches API

دستاویزات: [Message Batches](#)

7.1 Overview

Message Batches API asynchronous processing 50% savings، up to 24 hours window، اور، multi-turn tool calling supported، custom_id کے requests اور responses link میں

7.2 کب استعمال کریں

Pre-merge checks اور interactive tasks کے لیے synchronous API، overnight reports اور bulk jobs کے استعمال کریں Batch API کے لیے

7.3 custom_id

دوبارہ failed items کرنے، اور صرف failures identify، سد جوڑنے original document کو result custom_id submit کرنے میں مدد دیتا ہے

8: Task Decomposition Strategies

8.1 Fixed Pipelines

Predictable tasks fixed pipeline جیسے، Document → Extraction → Validation → Final output

8.2 Dynamic Decomposition

Open-ended tasks میں subtasks intermediate results کی بنیاد پر بنتے ہیں

8.3 Multi-pass Code Review

Large PRs کم ہو، attention dilution کریں تاکہ cross-file integration pass بعد per-file analysis کے لیے

9: Escalation اور Human-in-the-Loop

9.1 کریں Escalate کب

Explicit user request, policy gaps, progress نہ ہونا، threshold اوپر financial action، یا ambiguous matching میں صورت کی escalate کریں Sentiment analysis اور self-rated confidence unreliable ہیں

9.2 Escalation Patterns

human کو hand off ہو تو explicit insistence یا policy gap کرنے کی کوشش کریں، پھر اگر resolve ہو، مسئلہ حل کریں

9.3 Structured Handoff

Escalation پر human شامل کریں تاکہ recommended action اور، customer ID، issue summary، actions taken، context کو مکمل operator

9.4 Confidence Calibration

Field-level confidence scores, calibration on labeled data, اور stratified sampling استعمال کریں

10 Error Handling میں Multi-agent Systems: باب 10

10.1 Error Categories

Transient errors retryable ہیں، validation errors input fix ہیں مانگتی، business errors policy-driven ہوتی ہیں کی جاتی ہیں۔ permission errors generally escalate ہیں، اور

10.2 Anti-patterns

Generic “search unavailable” response, silent suppression, workflow abort یا پورا کرنا نقصان دہ۔ Structured errors واپس کریں

10.3 Structured Subagent Error

Structured error میں failure type, attempted query, partial results, alternative approaches, اور coverage شامل کریں impact

10.4 Final Synthesis میں Coverage

Report میں کون سی sections fully covered ہیں، کون سی partially covered ہیں، اور کون سی gaps باقی ہیں

11 Context میں Production Systems: باب 11

11.1 Facts Separate Block میں

Transactional facts کو persistent case facts block میں رکھیں تاکہ summarization باوجود critical data نہ ہو

11.2 Tool Results Trimming

PostToolUse hook رکھیں relevant fields سے صرف

11.3 Position-aware Input

کم □□ lost-in-the-middle effect آخر میں رکھیں تاکہ □□ action items شروع میں اور Important findings

11.4 Scratchpad Files

محفوظ □□□□ context میں long investigations میں لکھیں تاکہ □□ scratchpad Verbose findings

11.5 Subagents کو Delegate کرنا

رکھیں □□ summary میں صرف main context میں دیں اور Exploration subagents

11.6 Structured State Persistence

ممکن □□ crash recovery کر □□ تاکہ □□ export میں JSON file یا state manifest اپنی agent □□

12 کو محفوظ رکھنا Provenance: باب 12

12.1 Attribution Loss

رکھیں □□ confidence اور ، publication date، source URL □□ ساتھ Claim

12.2 Conflicting Data

کریں □□ conflict flag □□ ساتھ محفوظ رکھیں اور attribution دیں تو دونوں کو values مختلف sources اگر

12.3 Dates

دیکھیں □□ publication dates سمجھنے □□ سد □□ □□ contradiction کو Temporal differences

12.4 Content Type □□ Render

time series میں، اور technical findings structured lists ، news prose ، میں Financial data tables chronological order □□ دکھائیں

باب 13: Claude Code کے Built-in Tools

13.1 Tool Selection Reference

Task	Tool	Example
تلاش کرنا file کا pattern	Glob	<code>**/*.test.tsx</code>
file contents میں search	Grep	function name, error message
پڑھنا file	Read	analysis کا لپکا
بنانا file نیا	Write	scratch کا
precise edit	Edit	unique text match
shell command	Bash	git, npm, tests

13.2 Incremental Investigation

دیکھیں کہ consumer files، پھر usages، پھر entry points، پڑھیں؛ پھر لپکا files ایک ساتھ سب

13.3 Read + Write Fallback

کریں کہ Write کریں، پھر programmatically کریں، تبدیلی Read کا و تو Edit fail اگر

امتحانی ڈومین نوٹس: II حصہ

1 ڈومین: Agent Architecture اور Orchestration (27%)

Agentic loops, coordinator–subagent architecture, Task کا ذریعہ spawning, hooks, escalation, اور multi-step workflows پر فوکس کریں

2 ڈومین: Tool Design اور MCP Integration (18%)

Tool descriptions, tool_choice, JSON schema output, structured errors, MCP servers, resources, اور built-in tools کا فرق کو سمجھیں

سوال 62

فولٹا fail وقت 12% tool `search_catalog` سڈ معلوم ہوتا ہے آپ کا Production monitoring صورتحال میں جو کبھی query syntax errors پر کامیاب ہوتے ہیں، اور 4 retry میں جو network timeouts: 8 ہوتے ہیں، جس سڈ ہڈ فائدہ return یکساں طریقہ سڈ error types کامیاب نہیں ہوتے فی الحال دونوں retries ہوتی ہیں

کریں گے؟ modify کیسے error handling کی tool آپ

- A) System prompt میں few-shot examples شامل کریں جو network errors کیسے فرق کیسے کریں syntax errors
- B) کریں uniformly exponential backoff retry logic apply پر errors تمام
- C) Tool syntax errors کریں؛ automatic retry with backoff implement کی لیں network timeouts اندر Tool parameter validation details [درست] کی ساتھ فوری واپس کریں
- D) کی ساتھ واپس کریں error type details اور boolean flag `retryable` کو errors تمام

کو tool — abstraction boundary کرنا صحیح retries handle کی لیں transient errors پر Tool level: کیوں C پر agent کر سکتا ہے بغیر deterministic retry logic implement کی بار میں یقینی علم اور و error type Uniform backoff (B) syntax errors کر (A) follow prompt instructions کر یا (D) interpret flag انحصار کی و پر وقت ضائع کرتا ہے جو کبھی کامیاب نہیں ہوں گے errors

سوال 63

بہت کم risk tolerance اور "میری user، میں turns کی گفتگو کی کئی Investment strategy صورتحال کرنا چاہیے؟ invest کرنا چاہتا ہوں" اب و پوچھتا ہے: "مجھے کس چیز میں returns maximize پھر" میں اپن

سڈ priority کی اصل recommendation user سب سڈ بہتر طریقہ سڈ یقینی بنانا کی approach کونسا ہے؟

- A) پوچھیں کی کونسی چیز زیادہ اہم [درست] user تضاد کو سامنڈ لائن اور
- B) فراہم کریں recommendations کی لیں الگ الگ scenarios دونوں
- C) کی ساتھ آگے بڑھیں preference سب سڈ حال میں بیان کی گئی
- D) تجویز کریں balanced portfolio تضاد کو حل کیے بغیر

مانگنا کی واحد clarification برا راست متضاد ہوں، تو تضاد سامنڈ لانا اور preferences کی user کیوں: جب A low risk کرنا اور Returns maximize کی اصل ارادہ سڈ ہے آہنگ و recommendation user طریقہ کی بنیادی طور پر ناقابل مطابقت اڈاف میں جن کی لیں انسانی فیصلہ درکار tolerance

سوال 64

jazz کی "مجھے User کرتے ہیں playlist preferences refine میں conversation turns صورتحال پسند ہیں؟ genres پوچھتا ہے "آپ کو کون سا Claude، بعد messages پسند" کی دو

سب سڈ زیادہ ممکنہ وجہ کیا ہے؟

- A) Claude درکار vector database connection برقرار رکھنے کی لیں conversation memory کو

- B) Model کی context window exceed ہو گئی
- C) Claude API کو session_id parameter درکار
- D) شامل نہیں کر رہی [درست] messages array messages میں پچھلے application آپ کی

D کیوں: Claude پاس server-side memory کے request stateless ہیں — API call کے پاس Claude turns کے پاس پچھلے conversation history میں مکمل messages array کا کوئی علم نہیں؛ دو Claude architecture (C) session_id اور (A) Vector databases میں؛ context window overflow (B) ناممکن

سوال 65

History تک پہنچ گئی 78,000 tokens conversation، بعد cooking session صورتحال: 40 منٹ کے شامل ہیں آپ کو اہم معلومات discussion اور عمومی allergies, recipe scaling, clarified cooking terms، کم کرنے کے tokens محفوظ رکھتے ہوئے

کدام درمیان بہترین توازن رکھتا ہے؟ token reduction اور approach preservation کونسا

- A) خلاصہ کریں conversation history پوری
- B) رکھیں tokens صرف سب سے حالیہ 20,000
- C) خلاصہ کریں، اور discussion نکالیں، عمومی structured data (allergies, quantities, preferences) م رکھیں [درست] verbatim کو exchanges حالیہ
- D) retrieve کے ذریعہ متعلقہ حصہ semantic search کریں اور conversation externally store مکمل

C کیوں: Hybrid approach کم cost سب سے زیادہ valuable پر سب سے زیادہ cost کم summarization (summarization) میں extract compact structured block ایک critical facts جیسے recipe quantities اور exchanges ہوتی ہیں، اور حالیہ discussion summarize عمومی، (سب سے بچاتے ہوئے precision loss کے دوران conversational coherence کے لیے verbatim میں Options A اور B dietary information کے لیے D cooking session ایک ہیں؛

سوال 66

topics اور preferences کا خلاصہ assistant میں conversations رپورٹ کرتے ہیں کے طویل Users صورتحال رکھتی ہے message pairs صرف آخری 25 implementation حساب کھو دیتا ہے آپ کی موجود

کیا ہے؟ solution سب سے مؤثر

- A) Hybrid approach: messages verbatim [درست] خلاصہ کرتے ہوئے حالیہ messages پرانے
- B) vector similarity search پر conversation history مکمل
- C) Window 50 message pairs تک بڑھائیں
- D) آگے جوڑیں running summary خلاصہ کریں اور dropped messages میں turn

A کیوں: Hybrid approach exact recent context کے دونوں پہلوؤں کو حل کرتی ہے (conversational coherence کے لیے) compressed representation کی preferences جبکہ خلاصہ کی (context کو miss) Vector search صرف اسی مسئلہ کو ملتوی کرتا ہے (C) بڑھانا Window رکھتی ہے (D) semantically سب سے current query کر سکتی ہے

سوال 67

بڑھ جاتی latency سے زیادہ ٹوکن ہیں تو 50 turns conversations رپورٹ کرتے ہیں کہ جب Users: صورتحال بھی costs ہیں اور

بنیادی وجہ کیا ہے؟

- A) شامل ہوتی ہیں [درست] conversation history کے ساتھ پوری API request
- B) Model gradually responses generate کرتا ہے
- C) History کے ساتھ database operations میں جاتے ہیں بڑھنے کے ساتھ
- D) Model internal user profile کی ضرورت والا processing زیادہ بناتا ہے

A میں پوری array messages کو request — کے stateless مکمل طور پر API کی Claude: کیوں A زیادہ request بڑھتی ہیں، کے conversations شامل کرنی ہوتی ہیں جیسے جیسے conversation history کے درمیان کوئی Model calls دونوں بڑھانا cost اور directly processing latency لے جاتی ہے، جو tokens internal state رکھتا ہے (D غلط ہے)

سوال 68

تک بڑھ گئی ہیں جب conversation history 85,000 tokens کے بعد weekly sessions: صورتحال: تین مہینوں کے discussions پچھلی assistant کے بارے میں کیا نتیجہ اخذ کیا تھا؟، تو theme کے isolation پوچھتا ہے "م نہ user کرنے کے بجائے عام جوابات دیتا ہے reference

کیا ہے؟ approach سب سے مؤثر

- A) Rolling window truncation
- B) Key conclusions capture کے progressive summarization
- C) Relevant exchanges retrieve کے لیے [درست] semantic embeddings
- D) Discussion conclusions mark کے لیے structured XML tags شامل کریں

C scale کو discussion کے جو تین مہینوں کی approach واحد semantic search پر Conversation history Rolling window truncation کر سکتی ہے specific relevant exchanges surface پر demand کر سکتی ہے جبکہ truncation (A) history کے Progressive summarization (B) discussions کا بیشتر حصہ ضائع کر دے گی history (A) truncation پوچھتے ہیں کہ وہ users کے دیتی ہیں جن کے بارے میں specific conclusions، کرتی ہے compress میں abstractions

سوال 69

کرتا ہے، system prompt guidelines میں 10–15 Claude، کے دوران QA testing: صورتحال کے اندر token limits ابھی Conversation آ جانی ہیں deviation میں responses لیکن بعد کے

کیا ہے؟ solution بہترین

- A) Behavioral guidelines کے user message کو پلے میں منتقل کریں
- B) 20 turns کے بعد نئی conversation شروع کریں
- C) Conversation breakpoints پر guidelines reinforce والے user-role messages insert [درست] کریں
- D) Non-compliant responses کو regenerate کے لیے post-response validation کرنے کے استعمال کریں

history کا براہ راست مقابلہ کرتا ہے، periodic injection instruction drift کا Behavioral reminders کیوں C user کو پہلے Guidelines کر کے re-establish constraints پر regular intervals کو ساتھ accumulate message نہ کر کے Post-response validation (D) corrective کم کرتا ہے authority ان کا (A) میں منتقل کرنا preventive اور significant latency شامل کرتی ہے

سوال 70

adaptation rules اور teaching methodology کو جو 2,800-token system prompt میں AI tutor 2,800 صورتحال: آپ کے کو نظر انداز کرنا شروع کر دیتا ہے، assistant proficiency levels بعد 12 turns کرنا

کیا؟ fix سب سے مؤثر

- A) 5–4 turns میں inject reminders کریں
- B) Verbose rules کو proficiency-level adaptation demonstrate والے few-shot examples سے replace کریں [درست]
- C) Critical rules کو system prompt میں رکھیں
- D) Responses evaluate کر کے difficulty level match اور اگر regenerate نہ کرے تو

abstract rules کیونکہ vulnerable کے لیے 2,800-token system prompt drift Declarative rules کیوں B سے concrete few-shot examples کو Verbose rules کا تقاضا کرتے ہیں، reasoning سے model میں turn clear کرنے کے لیے match کو model، کریں، correct proficiency-level adaptation demonstrate کرنا جو replace behavioral patterns کئی turns دیتا ہے — یہ

سوال 71

clarifying کرنا، اور reasoning explain برقرار رکھنا، اپنی enthusiastic tone کو assistant صورتحال: آپ کے کو behavioral guidelines پوچھنے ہیں، یہ questions

ونی چاہئیں؟ define ان behavioral guidelines

- A) user message سے پہلے prepend کریں
- B) System prompt میں [درست]
- C) assistant message سے پہلے
- D) Environment variables میں

persistent behavioral کے لیے والی apply میں conversation خاص طور پر پوری System prompt کیوں B redundant (A) سے پہلے شامل کرنا user message کے لیے ڈیڑھ گھنٹہ کے لیے guidelines اور constraints assistant message (C) unreliable کیونکہ overhead سے deviate اپنے پہلے model کیونکہ assistant message (D) model behavior کے Environment variables کر سکتا ہے

سوال 72

جیسے "یقیناً!" اور "میں مدد کرنے میں خوش ہوں!" رپورٹ کرتے ہیں: Users repetitive response openings صورتحال

کیا approach سب سے مؤثر

- A) Direct response opening ساتھ partial assistant message append [درست] کریں
- B) Temperature setting کم کریں
- C) Greetings کو post-process کرنا، responses کو لے کر
- D) System prompt کی phrases میں ان instructions سے بچنا شامل کریں

A کیوں: Assistant کو direct response کے generation level پر greeting patterns کو generate کرنے کے لیے opening phrases کو بچانا، model prefill سے continue کرنا — روکنا patterns کو Post-processing (C) میں reliable مدد کر سکتی ہے لیکن کم (D) System prompt instructions fragile ایک (B) randomness control کرتا ہے، specific phrase patterns کے workaround

سوال 73

user کو گایا جبکہ package ship user کا کرتا ہے کہ notify کو system آپ کے webhook صورتحال: ایک شامل کرنا naturally میں response اس کے اگلا assistant کر رہا ہے آپ چاہتے ہیں کہ actively chat

کیا approach بہترین

- A) Shipping status کو system prompt میں شامل کریں
- B) synthetic user message فوری بھیجیں
- C) کرنا پر مجبور کریں کہ status tool call کو assistant میں turn کر
- D) Status update کو اگلا user message کے prefix طور پر append [درست] کریں

D کیوں: Status update کو aگلا user message کے prefix طور پر شامل کرنا کہ flow کو interrupt بغیر کہ natural conversation boundary پر real-time context inject کرنا System prompt modify کرنا (A) session rebuild کر سکتا ہے کہ Synthetic user message (B) natural dialogue flow کو disrupt کر ضرورت کی (C) tool call force میں events rare جب اس وقت (C) کرنا tool call force

سوال 74

Assistant 4+ clarifying questions میں requests کریں "جیسے venue book اکثر پارٹی کے لیے Users صورتحال questions 35 ہوتا ہے abandonment % پوچھتا ہے، جس سے 35

کرتا ہے؟ improve کو بہترین طریقہ سے approach trade-off کونسا

- A) Hidden defaults ساتھ آگے بڑھیں
- B) میں پوچھیں کہ compound message ایک clarifying questions تمام
- C) Assumptions explicitly بیان کریں اور corrections [درست] آگے بڑھیں
- D) Structured intake form استعمال کریں

C کیوں: Assumptions explicitly بیان کرنا اور آگے بڑھنا کہ user کو غلط response کو فوری، مفید user بیان کرنا اور آگے بڑھنا کہ Hidden defaults (A) user کو بتانا کہ کیا user بھر بھی Compound question list (B) upfront effort سے (D) Structured form کا تقاضا کرتی ہے کہ friction شامل کرنا کم (D) کی بجائے زیادہ

سوال 75

turns rules follow استعمال کرتا ہے ابتدائی assistant contractor-persona system prompt صورتحال: آپ کا Conversation length 2,500 tokens صرف دیتا ہے assistant generic advice تک 7 turn کرتا ہے، لیکن

سب سے زیادہ ممکنہ وجہ کیا ہے؟

- A) System prompts initial behavior establish کرتے ہیں صرف
- B) Turns accumulate کمزور ہوتی ہے attention کی model ہونے کے ساتھ
- C) Accumulated assistant responses system prompt اثر کو dilute [درست] کرتے ہیں
- D) System prompt صرف ایک بار بھیجا جاتا ہے

system prompt کے جمع ہونے میں assistant responses میں conversation history کیوں جیسے جیسے C کے assistant-generated content بڑھنے والے proportion کا text کرنے والے reflect کو behavioral constraints کے بجائے اپنے پیمائش system prompt instructions پر بھی token lengths چھوٹے Model کم ہوتا جاتا ہے relative کے compound کو drift، کرتا ہے follow کو زیادہ patterns کے outputs

سوال 76

کئی Assistant "میں مدد کر سکتے ہیں؟" report کرتے ہیں جیسے "کیا آپ requests میں Users صورتحال abandonment % جس سے 40، (کیا ہے deadline؟ کیا مدد؟ report کون سی) کرتا ہے respond سوالات پوچھ کر ہوتا ہے

کیا ہے solution بہترین

- A) Reasonable assumptions انہیں اور explicitly کریں،
- B) Respond smaller model کرنے سے پہلے
- C) Assumptions predefined interpretations بیان کیے بغیر
- D) Assistant turn کو رکنے تک محدود کریں clarifying question میں ایک

رکھتے ہیں in control اور informed کو user کے ساتھ آگے بڑھنا Reasonable stated assumptions کیوں A کرتی ہے confuse کو (C) users Silent predefined interpretations کو مکمل طور پر ختم کرتا ہے back-and-forth کی back-and-forth turns بھی (D) One-question limit، match ان کے ارادے سے response میں جب infrastructure اور latency مسئلہ حل کیے بغیر (B) core UX Smaller classification model ضرورت ہے شامل کرتا ہے complexity

عملی مشقیں

Exercise 1: Multi-tool Agent with Escalation Logic

Goal: tool integration، structured errors، اور escalation کے ساتھ agent loop بنائیں

Exercise 2: Configuring Claude Code for Team Development

Goal: CLAUDE.md, custom commands, path-specific rules, اور MCP servers configure کریں

Exercise 3: Structured Data Extraction Pipeline

Goal: JSON schema, validation/retry loops, اور Message Batches API کے ساتھ extraction pipeline بنائیں

Exercise 4: Designing and Debugging a Multi-agent Research Pipeline

Goal: subagent orchestration, explicit context passing, error propagation, اور source tracking implement کریں

Appendix: Technologies and Concepts

Technology	Key aspects
Claude Agent SDK	agent loops, <code>stop_reason</code> , hooks, <code>Task</code> , <code>allowedTools</code>
MCP	servers, tools, resources, <code>isError</code> , <code>.mcp.json</code>
Claude Code	CLAUDE.md, <code>.claude/rules/</code> , <code>.claude/commands/</code> , <code>.claude/skills/</code> , planning mode
Claude Code CLI	<code>-p</code> , <code>--output-format json</code> , <code>--json-schema</code>
Claude API	<code>tool_use</code> , <code>tool_choice</code> , <code>stop_reason</code> , <code>max_tokens</code>
Message Batches API	50% savings, 24-hour window, <code>custom_id</code>
JSON Schema	required/optional, nullable, enum values
Few-shot prompting	ambiguous scenarios کے لیے examples
Prompt chaining	sequential decomposition
Context window	token budget, lost-in-the-middle
Confidence calibration	field-level scoring, stratified sampling

Out-of-Scope Topics

یہ: موضوعات امتحان میں شامل نہیں ہیں

- Claude models کی fine-tuning
- Authentication, billing, یا account management
- implementation کی تفصیلی programming languages مخصوص
- MCP servers کی hosting/infrastructure
- Claude کی internal architecture یا model weights
- Constitutional AI, RLHF, یا safety training
- Embeddings یا vector databases کی implementation details
- Computer use / browser automation
- Vision / image analysis
- Streaming API یا SSE
- Rate limiting اور detailed API cost calculations
- OAuth اور API key rotation details
- Cloud-provider-specific configs
- Performance benchmarks
- Prompt caching implementation details
- Token counting algorithms

Preparation Recommendations

1. بنائیں agent کا ساتھ ایک Claude Agent SDK
2. کریں configure پر real project کو Claude Code
3. کریں test اور MCP tools design
4. بنائیں Data extraction pipeline
5. کریں Prompt engineering practice
6. سیکھیں Context management patterns
7. سمجھیں human-in-the-loop workflows اور Escalation
8. حل کریں Practice exam